

复杂场景下多模态情感预测的数学建模与算法设计

摘 要

多模态情感预测是情感计算与多模态学习交叉的重要问题，在自然人机交互、智能客服与心理健康监测等场景中有广泛的应用需求。真实环境中，设备异常、画面遮挡与转写失败都可能造成某一模态的连续时段失效，模型需要在信息不完整时仍给出稳定可靠的情感极性与强度估计，鲁棒预测与可信解释因此成为该问题落地的两个核心要求。针对这一问题，本文提出一套覆盖特征对齐、鲁棒建模与可解释分析的完整研究方案，以赛题给定的 CMU-MOSEI 派生数据为唯一数据来源，先以词级时间区间为公共锚点完成三模态特征提取与时序对齐，再建立掩码感知的多模态鲁棒融合模型，借助课程式缺失注入、动态专家门控与教师-学生蒸馏应对不同类型的局部缺失，进而在冻结的预测骨干上搭起模态级、片段级与证据级三层解释通路，对预测依据逐项做量化核验。整套方案在缺失场景下同时保住了预测稳定性与解释可复核性。

针对问题一，以词级时间区间作为三模态共同的对齐基准，将文本词序列、语音帧和视觉帧映射到统一的 50 个时间步，并根据零值结构推断每个样本的有效长度，用有效性掩码把尾部填充与有效区间内的真实缺失分开标注。该方案为全部样本建立了可追溯、可核验的输入规范，输出的特征文件与掩码可直接为后两问复用；示意样本的掩码时序对照显示，填充位与缺失位在掩码空间中完全可分离。

针对问题二，设计了掩码感知的多模态鲁棒融合模型 MRF-Net。编码器把缺失指示与可见指示并入每个时间步的输入，融合层先做共享-特有分解保留模态间的共性与个性，再由动态专家门控按样本的缺失结构分配专家权重；由于训练集中的真实缺失极少，训练阶段采用课程式缺失注入与教师-学生蒸馏，让模型从轻微的单模态缺失逐步适应到较深的多模态混合缺失。验证集上，模型取得 $MAE=0.5866$ 、 $ACC=0.6223$ 、 $Macro-F1=0.6158$ 、 $Pearson=0.6543$ ；测试划分上 $ACC=0.6534$ 、 $Macro-F1=0.6338$ ，二分类口径准确率为 0.8514。对 120 个缺失场景的三因素方差分析表明，性能退化主要由模态类型与缺失率的交互项主导，MRF-Net 将该交互的效应量由 0.9517 降至 0.8415，不同缺失位置下的整体退化幅度比朴素基线低 1.5 至 3.3 倍。训练损失曲线、六类缺失的退化曲线、消融对比与错误归因等可视化结果一致支持上述结论；在训练规模约为公开划分五分之一的条件下，二分类口径 0.8514 已达到公开干净设定的量级。

针对问题三，沿用冻结的预测骨干，完成模态级、片段级和证据级三层解释，其中模态级用精确枚举的 Shapley 值衡量各模态贡献，片段级结合积分梯度与遮挡分析定位关键区段，证据级把重要片段映射回原始文本、语音时段和视频关键帧。验证集全局 Shapley 值为文本 0.1842、语音 0.0004、视觉 0.0103；仅保留文本时平均绝对误差为 0.5936，已接近全模态模型的 0.5866；解释排序与问题二删模态退化结果的秩相关系数为 1.000，与附件三实测缺失率的免标注检验相关系数为 -0.4011。典型样本解释卡、模

态作用度分布、一致性散点与片段重要性热力图等可视化结果与统计结论相符；三源融合解释在忠实性与稀疏性之间取得折中，综合表现优于任何单一来源。

综合各项实验，本文模型在局部模态缺失条件下保持了稳定的预测性能。消融实验表明性能来源于掩码感知、缺失注入与门控融合的整体配合；缺失场景扫描、错误归因与拒识分析从不同角度验证了模型的可靠性；解释结论通过了删模态退化与附件三实测缺失两项独立检验。以上结果说明，该方案在鲁棒预测与可解释性两方面都经受住了独立检验，能够支撑复杂场景下多模态情感预测的实际需求。

关键字： 多模态情感预测；局部模态缺失；掩码感知融合；动态专家门控；可解释性评价

目录

一、问题重述	5
1.1 问题背景	5
1.2 本文拟解决的问题	5
二、模型假设与符号说明	6
2.1 模型的基本假设	6
2.2 模型符号说明	6
三、技术路线图	8
四、问题一模型的建立与求解	8
4.1 问题分析	8
4.2 模型建立与求解	8
4.3 结果分析与可视化	9
4.4 本章小结	9
五、问题二模型的建立与求解	9
5.1 问题分析	9
5.2 数据处理与分析	10
5.2.1 数据说明与预处理	10
5.2.2 模态缺失的数学刻画与模拟设计	11
5.2.3 缺失分布标定与输入条件	13
5.3 模型建立	13
5.3.1 掩码感知编码器	13
5.3.2 动态专家门控融合	15
5.3.3 多任务输出与目标函数	17
5.3.4 缺失鲁棒训练策略	18
5.3.5 决策阈值选择与校准	20
5.4 结果分析与可视化	22
5.4.1 评价指标与评估口径	22
5.4.2 基础性能评价	23
5.4.3 缺失模态类型、位置与时长的影响规律	25

5.4.4 消融实验与超参数搜索	29
5.4.5 错误归因与不确定性分析	31
5.4.6 附件三测试集预测结果汇总与展示	34
5.5 本章小结	37
六、问题三模型的建立与求解	37
6.1 问题分析	37
6.2 模型建立	38
6.2.1 可解释性的形式化定义与方案选择	38
6.2.2 可解释性证据头的结构与目标函数	40
6.2.3 模态级与片段级解释的计算	40
6.2.4 证据定位规则	42
6.3 结果分析与可视化	43
6.3.1 评价指标与解释质量度量	43
6.3.2 典型样本解释卡	43
6.3.3 三模态作用差异与一致性检验	46
6.3.4 片段级证据定位与可读性核查	49
6.3.5 附件四预测与解释结果汇总	51
6.4 本章小结	52
七、模型评价与推广	52
7.1 模型的优点	52
7.2 模型的缺点	53
7.3 模型改进与推广	53
参考文献	53
A 支撑材料文件清单	56
B 不确定性与拒识能力分析（补充实验）	57
C 核心代码	57

一、问题重述

1.1 问题背景

情感分析是具身智能与自然人机交互等领域的关键支撑技术之一。真实交互中，人类情绪通过文本语义、语音韵律、面部表情与肢体动作等多通道信号协同表达，多模态情感预测因此成为情感计算与多模态学习交叉的重要研究方向，在理论上需要刻画不同模态在情感表达中的互补与冗余关系，在应用上则支撑智能客服、心理健康监测与舆情分析等场景在复杂环境中给出可靠的情感极性与强度估计 [2]。

现有研究普遍采用深度网络进行多模态融合，借助注意力机制、图网络与预训练模型挖掘模态间的关联，在信息完整的基准数据集上取得了较高的识别精度。然而在实际工作中，这类方法面临明显的困难。真实采集环境里，设备异常、画面遮挡与转写失败都会造成某一模态的连续时段失效，而主流融合模型默认各模态完整可用，缺失值被置零后仍参与编码与聚合，性能随之下降；已有面向缺失的方法多依赖生成式补全或统一表示，补全质量难以保证，训练成本也较高。同时，深度模型大多是黑箱，难以说明判断主要依赖哪一种模态、哪些时间片段推动了判断，结果缺少可核验性。

针对上述困难，本文提出一套显式建模缺失并兼顾可解释性的完整方案，以词级时间区间为公共锚点完成三模态特征提取与时序对齐，将缺失状态编码为掩码并让掩码全程参与编码、池化与融合，配合动态专家门控与课程式缺失注入，使模型直接学习如何在不完整信息下做判断，并搭建起模态级、片段级与证据级三层解释通路，把预测依据落到可复核的原文词句、语音时段与关键帧。与依赖补全的方法相比，该方案不需要生成任何缺失数据，缺失处理过程透明可查；与纯预测模型相比，它在给出预测的同时附带经过独立检验的解释，鲁棒性与可信度都更经得起检验。赛题给出的三项任务与这一方案对应，先完成三模态特征提取与时序对齐，再研究局部模态缺失条件下的鲁棒情感预测，进而给出可量化、可复核的解释。

1.2 本文拟解决的问题

本文需要完成以下三项任务。

问题一（多模态特征提取与时序对齐）：基于附件一原始视频，分别提取文本、语音和视觉特征，并以词级时间区间作为公共锚点，使不同采样频率的特征对应到统一的 50 个时间步；对每个时间步同步记录有效性信息，以区分真实数据、尾部填充和有效区间内的缺失。

问题二（模态缺失条件下的鲁棒情感预测）：本文把缺失状态显式编码为掩码，使编码器、池化层和融合层能够识别不可用时间步；针对训练数据中真实缺失样本极少的问题，在训练阶段按照预设比例和位置注入连续缺失，并用附件三的实测缺失分布标定注入范围。随后从缺失模态类型、位置和时长三个维度进行系统扫描，分析性能退化规

律，并完成附件三的预测。

问题三（可解释性情感预测）：在不改变问题二预测骨干的前提下，分别从模态、时间片段和原始证据三个层次展开解释，先用 Shapley 值衡量模态贡献，再利用积分梯度和遮挡法定位关键时间步，把重要性回映到文本字符区间、语音时段和视觉关键帧。解释与问题二预测来自同一模型，两部分结果可以直接对照。

模型结构、超参数和决策阈值均只在附件二验证集上确定；附件三、附件四不参与任何模型选择，仅用于最终专项推理。

二、模型假设与符号说明

2.1 模型的基本假设

结合题意和数据结构，本文作如下假设。

假设一（样本独立性）：同一数据划分中的不同样本相互独立，不同样本的缺失模式不建立额外相关关系。该假设用于后续验证集指标统计和方差分析。

假设二（填充非缺失）：序列尾部连续全零部分视为填充，而非信息缺失。原因在于附件二缺少显式长度字段，且全零区间集中出现在序列尾部；若将其计入缺失，会系统性高估缺失率。

假设三（连续零判缺）：有效区间内连续不少于两帧的全零片段视为局部缺失，孤立单帧全零不直接判缺，以避免将特征归一化后自然出现的零值误判为缺失。该规则同时用于实测缺失统计和训练期缺失注入。

假设四（编码同源）：附件三、附件四的文本模态与附件二文本特征同源。编码一致性检验的余弦相似度为 1.0000，可支持后续统一建模。

假设五（标注噪声）：情感强度标签存在主观标注差异，因此连续回归结果可能向条件均值收缩。本文在误差分析中单独考察这一现象。

假设六（缺失可迁移）：训练阶段模拟注入的缺失类型、位置和强度与附件三实测分布处于同一量级，从而使缺失鲁棒性能够迁移到专项测试场景。

2.2 模型符号说明

全文所用主要符号、含义与单位汇总于表 1。符号按在正文中首次出现的顺序排列，后续各节的公式与产物均沿用同一套符号。

表 1 全文主要符号、含义与单位对照

符号	含义	单位
m	模态编号, $m \in \{\text{t}, \text{a}, \text{v}\}$ 分别表示文本、语音、视觉	—
T	对齐后的时间步数 (统一取 $T = 50$)	帧
$\mathbf{X}^m$	第 m 模态的特征矩阵, $\mathbf{X}^m \in \mathbb{R}^{T \times d_m}$	—
d_m	第 m 模态的特征维度	—
$\mathbf{P}^m$	填充掩码, $P_k^m = 1$ 表示第 k 段为尾部填充	—
$\mathbf{M}^m$	缺失掩码, $M_k^m = 1$ 表示第 k 段在有效区间内不可用	—
L_m	第 m 模态的有效长度	帧
ρ_m	第 m 模态的缺失率	—
$\mathbf{e}_m(t)$	第 m 模态第 t 帧的编码表示	—
$\mathbf{s}(t), \mathbf{d}_m(t)$	跨模态共享分量与第 m 模态的特有分量	—
g_m	模态门控权重	—
$\mathbf{z}$	融合后的样本级表示	—
μ, σ^2	情感强度的预测均值与预测方差	—
π	极性分类头的三类概率	—
θ	极性决策阈值	—
α, β	强度仿射校准的斜率与截距	—
φ_m	模态 m 的 Shapley 作用度	—
$\mathbf{w}^m$	模态 m 内各时间步的重要性向量	—
y, c	情感强度真值与极性类别真值	—
KL	Kullback–Leibler 散度	—

三、技术路线图




图 1 本文总体建模架构（五层技术路线）

四、问题一模型的建立与求解

本章为骨架占位：问题一的特征提取与时序对齐流程尚在完善中，待全量特征结果完成后补充（提交前必须补齐本节内容，否则与摘要及后文相关表述不一致）；其输入接口口径已在第 2 章的假设与符号体系中固化。

4.1 问题分析

（待补：明确附件一的输入形式、三模态输出特征、统一时间轴的定义，以及特征提取与对齐过程中最需要解决的时间粒度差异。）

4.2 模型建立与求解

（待补：给出文本、语音、视觉三模态的具体特征定义、提取工具及版本，说明词级时间锚点的构造方式、跨模态聚合规则和最终 50 步序列的生成过程。）

4.3 结果分析与可视化

（待补：至少给出对齐后的有效长度统计、典型样本的跨模态时间线，以及能够证明“词级对齐有效”的定量或可视化结果。）

4.4 本章小结

（待问题一实验完成后补写。本节概括本章完成了什么、输出了什么，不再重复方法细节。）

五、问题二模型的建立与求解

5.1 问题分析

实际采集中的局部缺失通常不是整条模态完全消失，而是某一连续时间段失效；缺失值被置零后仍会参与编码和聚合，固定权重融合模型无法识别这些不可用区段，预测因而受到明显干扰，而附件二训练集中的真实缺失样本极少（有效区间内真缺失率分别为文本 0、语音约 0.0004、视觉约 0.01），模型无法仅靠现有数据学会应对缺失。因此，本问一方面需要让模型在训练数据无法覆盖所有真实缺失模式的情况下，仍能对不同模态、不同位置 and 不同长时的局部缺失保持稳定，另一方面需要定量说明缺失类型、位置与时长对性能的影响，其结论也作为问题三解释分析的对照基准。这两项要求的必要性直接体现在提交任务上。附件三的 30 条样本中，语音与视觉分别有 17 条和 18 条包含连续缺失片段且以头部为主，本问的输出质量决定专项测试的提交结果。

本问的求解可以拆分为四个环节。从数据准备与缺失标定开始，针对附件二无长度字段、填充与缺失易混淆的特点，由尾部全零结构推断有效长度，构造填充掩码与缺失掩码把两类零严格分离，并让训练期注入的比例与位置按附件三的实测分布标定；该口径统一、可逐样本复核，为后续环节准备了干净一致的输入。随后建立掩码感知的鲁棒预测模型。编码器把缺失指示与可见指示并入每个时间步的输入，融合层先做共享-特有分解保留模态间的共性与个性，再由动态专家门控按样本的缺失结构分配专家权重；该方案不依赖生成式补全，缺失处理过程透明可查，得到同时输出情感极性与强度的预测骨干。进而开展课程式鲁棒训练。训练针对真实缺失极少的问题，按由易到难的课程注入缺失，借助教师-学生蒸馏拿到接近完整的监督，并用指数滑动平均稳定参数；这一安排避免了训练早期因缺失过强而优化不稳，使模型平稳地从轻度缺失过渡到较深缺失，训练完成后在验证集上选定阈值并冻结交付权重。评测与推广分析紧随其后，在统一协议下扫描 120 个缺失场景并做三因素方差分析，配合模块消融、多维错误归因与不确定性拒识，不仅给出性能均值，还定位主导退化的因素与典型失效模式，并完成附件三的推理与提交文件生成。整体求解流程如图 2 所示。




图 2 问题二的求解流程

5.2 数据处理与分析

5.2.1 数据说明与预处理

附件二的对齐版本以 Python 字典形式组织，包含 train/valid/test 三个划分，每条样本包含原始转写、三模态特征、三分类标签与区间 $[-3, 3]$ 内的连续情感强度标签。与赛题说明相比，实际文件缺少 audio_lengths、vision_lengths 和 annotations 三个字段，因此需要在读入阶段补充有效长度推断与标准化两步处理。

(1) **有效长度推断**：对每个样本和每个模态，从序列末端向前寻找最后一个非零时间步，并将其及之前的时间步定义为有效区间；有效区间内连续不少于两帧的全零片段判为局部缺失。该规则同时用于训练阶段的缺失注入和附件三的实测缺失统计，保证不同实验使用同一口径。

(2) **标准化**：三模态特征按维度进行 z-score 标准化，均值和标准差只使用训练集估计，避免验证集和测试划分的信息进入训练过程；原始填充位置不参与统计，也不因标准化而改变。

数据概况如表 2 所示。文本模态由预训练语言模型编码得到，有效长度恒为 50 帧；语音与视觉的平均有效长度分别约为 24.6 与 23.8 帧，因此同一缺失率水平下，文本损失的绝对帧数约为另两者的两倍。这一口径差异在 5.4.3 节做了专门的稳健性核验。

表 2 数据划分与特征概况

项目	数值
样本总数	4850 (训练 3395 / 验证 728 / 测试 727)
特征形状	文本 (N,50,768); 语音 (N,50,74); 视觉 (N,50,35)
类别分布 (训练集)	负向 967 / 中性 758 / 正向 1670
有效长度 (验证集实测)	文本 50.0; 语音 24.59 (10 至 90 分位 11 至 44); 视觉 23.82 (9 至 43)
填充率	约 0.49 至 0.54
有效区间内真缺失率	文本 0; 语音 0.0004; 视觉约 0.01
缺失字段	无 audio_lengths / vision_lengths / annotations

附件三、附件四逐文件存储（每条样本一个文件），且没有预计算文本特征。本文使用与附件二一致的预训练语言模型重新编码转写文本，并通过同源样本余弦相似度 1.0000 验证编码一致性，特征版本也与附件二保持一致。附件四属于问题三专项数据，在问题二训练与模型选择阶段不使用。

5.2.2 模态缺失的数学刻画与模拟设计

设样本第 m 个模态 ($m \in \{t, a, v\}$) 的特征矩阵为 $\mathbf{X}^m \in \mathbb{R}^{T \times d_m}$ ，其中 $T = 50$ 为序列长度；缺失位置由二值掩码 $\mathbf{M}^m \in \{0, 1\}^T$ 刻画， $M_k^m = 1$ 表示第 k 段不可用。缺失后的特征与缺失率分别定义为

$$\tilde{\mathbf{X}}^m = \mathbf{X}^m \odot (1 - \mathbf{M}^m), \quad \rho^m = \frac{\sum_{k=1}^{L_m} M_k^m}{L_m}, \quad (1)$$

其中 L_m 为该样本模态 m 的有效区间长度，式 (1) 给出的缺失率即全章统一采用的实测口径。训练阶段只在有效区间内注入连续缺失：将长度为 $L = \text{round}(\rho L_m)$ 的随机连续片段置零，并枚举头部、中部、尾部与随机四种位置，同时保留对应掩码，使训练阶段注入的缺失与推理阶段检测到的缺失使用同一数据表示。图 3 以一条真实样本为例展示两类掩码的时序对照，填充位于序列尾部、不携带任何信息；缺失位于有效区间内部、可以出现在任意相对位置；二者在掩码空间中完全可分离（图中灰底为尾部填充位、彩色段为有效区间、深色条为缺失片段）。正是这一可分离性，支持 5.3.1 节把掩码作为显式输入而非隐含信息。




图 3 填充掩码与缺失掩码的时序可视化（示例样本）

为了让模型在训练中见到足够多样的缺失结构，本章设计了一套随机化注入协议。每个训练批次随机抽取缺失模态组合、缺失位置和缺失强度。缺失类型包括仅文本、仅语音、仅视觉及两两组合共 6 类，位置包括头部、中部、尾部和随机 4 类，每个模态允许出现 1 至 3 段碎片化缺失。缺失强度按课程学习逐步增加，训练前期只注入单模态低强度缺失（ $\rho \leq 0.10$ ），中期加入多模态混合缺失（ ρ 约 0.04 至 0.20），后期把强度上限提高到 0.25。训练全程保留完整标签，缺失只通过掩码注入特征层，注入与检测共用同一套掩码判定规则，训练阶段的缺失形态与推理阶段保持一致。

需要注意，赛题要求分析缺失时长的影响，而本章的注入实验与场景扫描均以缺失率为控制变量，两者的换算关系需要先厘清（表 3）。文本的有效长度恒为 50 帧，缺失率 0.1、0.2、0.3、0.5 分别对应 5、10、15、25 帧；语音与视觉的平均有效长度仅约 24 帧，同一缺失率对应的绝对帧数大约只有文本的一半。这意味着相同的缺失率并不代表相同的缺失时长，缺失率 0.3 在文本上意味着 15 帧不可用，在视觉上只有约 7 帧。为排除这一口径差异对结论的干扰，5.4.3 节将在匹配绝对缺失帧数的条件下重做关键对比。

表 3 缺失率与平均绝对缺失帧数的换算

缺失率	文本（帧）	语音（帧）	视觉（帧）
0.1	5.0	2.5	2.4
0.2	10.0	4.9	4.8
0.3	15.0	7.4	7.2
0.5	25.0	12.3	11.9
1.0	50.0	24.6	23.8

5.2.3 缺失分布标定与输入条件

附件三共有 30 条样本，其实测缺失结构如表 4 与图 4 所示（左轴为含缺失样本条数、右轴为平均缺失率）。表中缺失率按 5.2.1 节的统一定义逐样本统计，位置比例按缺失帧落在有效区间前、中、后三段的份额计算。文本模态没有任何实测缺失；语音与视觉分别有 17 条（56.7%）与 18 条（60.0%）含缺失，平均缺失率为 0.1011 与 0.1072，90 分位约 0.224、最大值约 0.40；缺失位置偏有效区间前部（语音头部占比 0.46、视觉 0.43）。总体上，附件三属于中等强度、以视听模态为主、偏向头部的局部缺失场景。

表 4 附件三实测缺失结构（ $n = 30$ ）

模态	含缺失样本	平均缺失率	90 分位	最大值	位置（头/中/尾）
文本	0/30	0.0000	—	—	—
语音	17/30（56.7%）	0.1011	0.224	0.400	0.46 / 0.27 / 0.27
视觉	18/30（60.0%）	0.1072	0.224	0.400	0.43 / 0.29 / 0.29




图 4 附件三与附件四的模态缺失分布

有两处结构差异需要交代清楚。一处是位置先验的取向，注入协议默认以中部为主，而附件三实测以头部为主；前期对照实验表明，把位置先验调成头部为主并不会带来稳定收益（视听局部缺失造成的退化不足 1%），因此本章仍采用原注入协议。另一处在于监督的空白，附件三与附件四都没有文本模态实测缺失，文本分支的鲁棒性只能依靠训练期注入检验，本章在 5.5 节小结中一并说明这一局限。

5.3 模型建立

5.3.1 掩码感知编码器

掩码感知编码器是问题二模型的输入侧基础模块。其基本原理是在特征数值之外显式携带每个时间步的可用性状态，使网络始终能够区分真实观测的零与缺失造成的零，并把这一区分持续传递到池化与融合阶段。编码器处理的是一条带可用性标注的残缺序列，而不是被零填满的伪完整序列。该编码器由输入表示、局部卷积、自注意力编码与

共享-特有分解四个环节串联组成，三种模态结构相同、参数彼此独立；其输入构造与有效位加权池化的示意如图 5 所示。下面先说明这一设计的取舍，再按数据流顺序展开。

在路线选择上，缺失序列的常见建模方式有三条，分别是先补全并按完整序列处理、直接舍弃缺失片段，以及保留原样、仅在损失层面做鲁棒化。第一条途径的补全值并非真实观测，其偏差会沿时间轴向下游传播，甚至把模型引向虚假的情感线索；第二条途径既破坏时间轴的对齐结构，也丢失了缺失位置本身携带的信息，而本赛题中缺失源于静音、黑屏等真实因素，缺失的位置与形态往往与内容相关；第三条途径则始终无法让网络区分真实观测的零与缺失造成的零。我们在第三条途径上再进一步，采用掩码感知的输入设计，不补全也不丢弃，把可用性状态提升为与特征并列的输入信号，使缺失结构在整条数据流中保持可见，也为 5.4 节对缺失规律的分析保留了模型内部的对应依据。

具体而言，局部缺失被置零后，数值零可能同时表示该时间步无信息与该特征本身取零，只输入特征矩阵无法区分这两种情况。为此，我们把缺失指示与可见指示作为附加通道，与原特征共同输入编码器，使每个时间步的输入显式携带自身的可用状态：

$$\mathbf{u}_t^m = [\hat{\mathbf{x}}_t^m \parallel M_t^m \parallel 1 - M_t^m] \in \mathbb{R}^{d_m+2}, \quad \mathbf{h}_m^{(0)}(t) = \text{GELU}(W_{\text{in}} \mathbf{u}_t^m + b_{\text{in}}). \quad (2)$$

这样两类零在输入层即可区分，填充位由有效长度指示，缺失位由掩码指示，模型看到的是标注了可用性状态的残缺序列，而不是被零填满的完整序列。图 5 用一条示意样本概括该机制，灰段为尾部填充、彩色段为有效区间、斜纹段为缺失片段；填充位不进入池化统计，缺失位则始终以掩码标注的形式参与编码与融合，网络处理的是有效位加权表示与可用性指示的组合。




图 5 掩码感知输入与有效位加权池化示意

输入表示确定后，进入序列编码环节。情感线索在时间上呈现两种尺度，语调起伏、表情突变等短时变化决定局部形态，而整段语义的走向需要长程上下文才能判断；单一

结构难以同时覆盖两端，因为纯卷积的感受野受限，而纯注意力对短时突变不够敏感。为此，编码器按局部变化与长程依赖两级结构对序列建模，先投影到统一隐空间，再通过一层轻量的一维卷积提取局部变化（窗口 3、残差连接），并叠加位置编码后送入 L_e 层 Transformer 编码器：

$$\check{\mathbf{h}} = \mathbf{h}^{(0)} + \text{GELU}(\text{Conv1d}_3(\mathbf{h}^{(0)})), \quad \mathbf{h}_m = \text{Enc}(\check{\mathbf{h}} + \mathbf{p}), \quad (3)$$

其中位置编码 $\mathbf{p}$ 使模型能够区分时间先后；卷积层负责短时变化模式，自注意力层整合长程依赖与跨段信息。编码器以填充掩码作为注意力屏蔽项，尾部填充不参与任何信息聚合；三种模态使用相同的编码结构但参数彼此独立，最终统一映射到维度 d 的表示空间，便于后续的共享与融合计算。

编码完成后进入表示分解环节。三模态表示若直接拼接送入融合层，模型需要在有限样本下自行摸索哪些跨模态信息应当对齐、哪些应当保持独立，学习负担较重；更关键的是，某模态缺失时其表示已不可靠，仅靠拼接很难让其余模态及时补位。为此，我们显式地把表示解耦为共享分量与模态特有分量，编码输出经两个投影头解耦，再拼接映射回统一表示，并通过相似性约束和差异性约束限制两类表示之间的关系：

$$\mathbf{s}_m = W_s \mathbf{h}'_m, \quad \mathbf{d}_m = W_d \mathbf{h}'_m, \quad \mathbf{e}_m = W_{\text{mix}}[\mathbf{s}_m \parallel \mathbf{d}_m], \quad (4)$$

其中 $\mathbf{h}'_m$ 为经代理令牌修正后的编码表示（见 5.3.2 节）；共享分量承载跨模态共有的情感线索，特有分量保留各模态独有信息。为使两类分量可辨识，训练中加入两项正则，其中相似性项把不同模态的共享分量拉近，差异性项抑制同一模态内共享与特有分量的信息重叠：

$$\mathcal{L}_{\text{sim}} = \frac{1}{3} \sum_{m < m'} \|\bar{\mathbf{s}}_m - \bar{\mathbf{s}}_{m'}\|_2^2, \quad \mathcal{L}_{\text{diff}} = \frac{1}{3} \sum_m \overline{(\cos(\mathbf{s}_m, \mathbf{d}_m))^2}, \quad (5)$$

式中 $\bar{\mathbf{s}}_m$ 为共享分量在有效位上的均值池化，第二式的横线表示在有效时间步上取平均。至此，掩码信号已从输入构造贯穿至表示分解，构成模型缺失感知能力的第一处关键机制；分解得到的表示随即进入下一节的专家门控融合。

5.3.2 动态专家门控融合

动态专家门控融合是问题二模型的第二个核心模块。其基本原理是让信息路由随样本的缺失结构自适应变化，缺失越严重的模态越依赖可学习的代理表示兜底，缺失组合不同的样本则被路由到不同的专家权重上，从而在部分模态不可用时仍能稳定地合成样本级表示。该模块由代理令牌修正、门控网络与专家合成、掩码感知池化三个环节构成，分别应对单模态退化、模态组合差异与时间步可信度三个层面的问题；其整体数据

流如图 6 所示。下面先说明融合方式的选择依据，再依次展开三个环节。

更直接的做法是固定融合函数，把三模态表示拼接或加权求和后送入统一网络。但它要求同一组参数同时服务差异极大的输入分布，三模态齐全与文本全缺的样本在最优融合策略上几乎没有共性，参数只能在各种模式之间折衷，对每一种模式都难以达到最优。我们因此把路由与融合分开设计，保留一组结构相同、参数互异的专家，由门控网络依据样本的缺失结构分配专家权重，缺失组合不同的样本被分发到不同的子网络，模型无需为每种模式单独训练，却获得了针对性融合的能力；这一条件计算设计还使容量与开销解耦，模型总容量随专家数增长，单个样本的激活量却基本不变。

先处理模态级的退化问题。某一模态缺失严重时，其编码结果本质上是零填充经网络变换的产物，分布与真实观测差异明显，直接送入融合相当于让噪声参与全局表示，缺失越重、污染越大；反过来，硬性剔除该模态又浪费了它尚未缺失的部分。我们的折中方案是为每个模态设置可学习的代理令牌 $\mathbf{p}_m$ （可理解为该模态在训练集上的平均情感表达），并根据缺失率与当前编码状态计算门控系数 β_m ，在代理令牌与原表示之间插值：

$$\beta_m = \sigma(w_\beta^\top [\bar{\mathbf{h}}_m; \rho_m] + b_\beta), \quad \mathbf{h}'_m = (1 - \beta_m) \mathbf{h}_m + \beta_m \mathbf{p}_m, \quad (6)$$

其中 $\bar{\mathbf{h}}_m$ 为编码表示的有效位均值， ρ_m 为该模态缺失率。缺失越严重的模态， β_m 越大、越依赖代理表示兜底。

代理修正之后进入融合阶段的样本级路由。门控网络为每个样本动态分配专家权重，其输入由融合表示与缺失结构统计量共同构成。缺失结构统计量共 7 维，包括三模态缺失率、三模态可用指示（缺失率低于 1 时置 1）与可用模态数比例：

$$\mathbf{u} = [\rho_t, \rho_a, \rho_v, \mathbb{I}(\rho_t < 1), \mathbb{I}(\rho_a < 1), \mathbb{I}(\rho_v < 1), n_{\text{vis}}/3], \quad (7)$$

将三模态表示拼接为令牌序列并加入模态嵌入后，门控权重与专家融合输出为

$$\mathbf{g} = \text{softmax}\left(W_2 \text{GELU}(W_1[\text{tok}; \mathbf{u}])\right), \quad \mathbf{z}_f(t) = \sum_{e=1}^{n_E} g_e \cdot \text{Expert}_e(\text{tok})(t), \quad (8)$$

式中 tok 为令牌序列的有效位均值表示。各专家为结构相同的跨模态、跨时间自注意力子网络（含多头注意力、前馈与层归一化），门控权重随样本缺失结构自适应变化。为防专家坍塌（权重集中到少数专家），加入熵形式的负载均衡正则：

$$\mathcal{L}_{\text{bal}} = -n_E \sum_{e=1}^{n_E} \bar{g}_e \ln(\bar{g}_e + \epsilon), \quad (9)$$

其中 $\bar{g}_e$ 为批内专家 e 的平均门控权重；当各专家被均匀使用时该式取最小值。

专家输出再经掩码感知的注意力池化压缩为样本级表示，以可学习打分函数为每个时间步计算重要性，并在 softmax 前对填充位作屏蔽，使其退出有效统计：

$$\alpha_t = \frac{\exp(s(z_f(t)))}{\sum_{t'} \exp(s(z_f(t')))}, \quad z = \sum_{t=1}^T \alpha_t z_f(t), \quad (10)$$

式中求和仅覆盖非填充时间步， $s(\cdot)$ 为打分函数。图 6 展示该模块的数据流，三个模态经掩码感知编码与共享-特有分解后拼接为令牌序列，门控网络读取缺失结构统计量与融合表示，为全部专家生成样本级权重；专家输出按权重合成后再经注意力池化得到样本级表示 z 。缺失模式一变、路由权重随之改变，这是模型缺失感知能力的第二处关键机制。




图 6 动态专家门控融合示意

5.3.3 多任务输出与目标函数

编码与融合得到样本级表示 z 后，模型还需将其映射为具体任务输出并定义优化目标。模型同时优化情感强度与情感极性，强度回归头输出预测均值与对数方差，主损失采用加权平滑 L1（Huber 型， $\beta_s = 0.15$ ），并叠加小权重的高斯负对数似然项，以便在预测强度的同时估计逐样本不确定度：

$$\mathcal{L}_{\text{reg}} = \mathcal{L}_{\text{Huber}}(\mu, y) + \lambda_{\text{var}} \cdot \frac{1}{N} \sum_{i=1}^N \left[\frac{(y_i - \mu_i)^2}{2\sigma_i^2} + \frac{1}{2} \ln \sigma_i^2 \right], \quad \sigma_i^2 = \text{softplus}(s_i) + \sigma_0^2, \quad (11)$$

其中 $\lambda_{\text{var}} = 0.1$ ；平滑 L1 对强情感样本的极端误差更稳健，负对数似然项则保证逐样本方差可用（供 5.4.5 节的不确定性分析使用）。极性分类头采用类平衡交叉熵应对类别不平衡（训练集负/中/正约为 967/758/1670），并叠加标签平滑、弱标注降权与中性类抑制：

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N \omega_{c_i} \sum_{k=0}^2 \mathbb{I}[c_i = k] \ln \pi_{i,k}, \quad \omega_k \propto \frac{1}{n_k}, \quad (12)$$

式中 ω_k 截断于区间 $[0.2, 10]$ 以抑制极端类权重；弱标注 ($|y| \leq 0.5$) 样本的分类损失按 0.5 降权，中性类抑制项权重 0.25，另设强度软目标 EMD 项（权重 0.3）为分类头补充幅值侧信息。有序回归辅助头进一步把强度绝对值离散为 $K = 10$ 个有序档位，以累积链接模型（CORAL）[4] 施加序数监督，强制模型在零点附近建立分辨率：

$$\mathcal{L}_{\text{CORAL}} = -\frac{1}{N(K-1)} \sum_{i=1}^N \sum_{j=0}^{K-2} \left[\tilde{k}_i > j \right] \ln \varsigma_{i,j} + \left[\tilde{k}_i \leq j \right] \ln(1 - \varsigma_{i,j}), \quad (13)$$

其中 $\varsigma_{i,j} = \text{sigmoid}(w^\top z_i + b_j)$ 为累积概率，阈值 $\{b_j\}$ 可学习、按线性初值排布。总目标函数由上述各项与分解正则、均衡正则共同组成：

$$\mathcal{L} = \mathcal{L}_{\text{reg}} + \lambda_1 \mathcal{L}_{\text{cls}} + \lambda_3 \mathcal{L}_{\text{sim}} + \lambda_4 \mathcal{L}_{\text{diff}} + \lambda_5 \mathcal{L}_{\text{bal}} + \lambda_6 \mathcal{L}_{\text{CORAL}} + \lambda_7 \mathcal{L}_{\text{KD}} + \lambda_2 \mathcal{L}_{\text{rec}}, \quad (14)$$

其中权重分别取 $\lambda_1 = 1.0$ 、 $\lambda_3 = \lambda_4 = 0.5$ 、 $\lambda_5 = 0.01$ 、 $\lambda_6 = 0.5$ 、 λ_7 随轮数衰减（见 5.3.4 节）。跨模态重建项在最终部署配方中被关闭（ $\lambda_2 = 0$ ）。模型搜索起点包含以缺失位置为目标的重建约束，但消融实验显示关闭重建后误差与宏观 F1 同时改善（见 5.4.4 节），因此最终配方不含该项。

5.3.4 缺失鲁棒训练策略

目标函数之外，训练过程本身也需要针对缺失场景专门设计。训练期的缺失注入按课程学习方式 [6] 由易到难推进，共分三段，第 1 至 8 轮仅注入单模态缺失、强度不超过 0.10；第 9 至 20 轮引入多模态混合缺失、强度区间为 $[0.04, 0.20]$ ；第 21 轮起把强度上限抬高至 0.25：

$$\rho \in \begin{cases} [0, 0.10], & 1 \leq e \leq 8 \quad (\text{单模态}), \\ [0.04, 0.20], & 9 \leq e \leq 20 \quad (\text{混合模态}), \\ [0.04, 0.25], & e \geq 21 \quad (\text{混合模态}). \end{cases} \quad (15)$$

由浅入深的安排让模型先建立完整信息下的基本映射，再逐步适应更复杂的缺失结构，避免训练早期因缺失过强而优化不稳。注入缺失的位置先验为中部 4/9、头部 3/9、尾部与随机各 1/9；每个模态允许 1 至 3 段碎片化缺失。

训练进一步采用教师-学生蒸馏，教师模型在固定中等缺失强度下训练，学生模型接受课程式缺失注入，并通过输出层软标签、强度回归与样本间关系三类蒸馏信号 [5]，

从教师模型获得相对完整的监督信号：

$$\mathcal{L}_{\text{KD}} = \text{KL}(\text{softmax}(\mathbf{o}^T/\tau) \parallel \text{softmax}(\mathbf{o}^S/\tau)) \cdot \tau^2 + \|\mu^T - \mu^S\|^2 + 0.1 \|\mathbf{R}^T - \mathbf{R}^S\|^2, \quad (16)$$

式中 $\tau = 2.0$ 为蒸馏温度， $\mathbf{R}$ 为批内样本表示的相似度矩阵（关系蒸馏项降权至 0.1，避免量级压过任务损失）。蒸馏权重随训练轮数指数衰减，后期逐渐让位于任务损失本身：

$$\lambda_{\text{KD}}(e) = 0.3 \exp(-e/15). \quad (17)$$

图 7 概括完整流程，左图为缺失注入的课程安排（教师阶段固定中等强度，学生阶段按三段区间递进），右图为蒸馏权重的指数衰减曲线；下方三框对应阶段一、阶段二与最终交付。两步合起来实现先学稳、再学缺的效果，教师端给出干净的监督，学生逐步逼近部署时的缺失场景，交付时只保留学生模型。




图 7 两阶段课程式缺失训练示意

其余稳定性措施包括参数指数滑动平均（衰减 0.99，用于平滑参数轨迹并作为交付权重）、时间裁剪（至少保留 70% 长度）、特征高斯噪声（ $\sigma = 0.15$ ）与整模态丢弃（概率 0.15）等数据增强，以及配合余弦退火学习率的 AdamW 优化。综合上述设计，两阶段训练的完整流程包含四个步骤。（1）按固定中等强度训练教师模型 12 轮并冻结其参数；（2）以三段课程注入训练学生模型 14 轮，同期叠加蒸馏与多任务损失（早停监控验证集误差，耐心 8 轮）；（3）对种子 42 与 43 的学生模型作集成，并在验证集上确定决策阈值；（4）固定全部参数，对附件三与附件四执行推理并生成提交文件。图 8 给出训练过程的损失与验证指标曲线，教师与学生阶段衔接平稳，验证误差在第 10 轮左右进入平台区，没有明显过拟合。




图 8 训练损失与验证指标随轮数的变化

5.3.5 决策阈值选择与校准

模型结构确定后，推理阶段还需明确极性的决策规则。情感极性的主输出来自分类头 argmax ，同时保留按连续强度与对称阈值划分极性的对照口径。题目规定决策阈值必须在验证集上选择；我们采用单一对称阈值，当预测强度 $\hat{y} < -\theta$ 时判为负类， $|\hat{y}| \leq \theta$ 时判为中性， $\hat{y} > \theta$ 时判为正类。阈值只在验证集上搜索，以宏观 F1 最大为目标：

$$\theta^* = \arg \max_{\theta \in \Theta} \text{MacroF1}(\{\text{polar}(\hat{y}_i, \theta)\}, \{c_i\}), \quad \Theta = \{0, 0.02, \dots, 1.50\}. \quad (18)$$

据此选定阈值 $\theta = 0.325$ （仅由验证集拟合）。图 9 的敏感性曲线表明，该值位于准确率和宏观 F1 的稳定平台附近（两者在 0.28 附近同步达到峰值），小范围阈值扰动不会明显改变结果。




图 9 决策阈值敏感性曲线

考虑到回归输出存在向零收缩，我们同时给出仿射校准作为对照 [8]，其系数同样只在验证集上估计：

$$(\alpha^*, \beta^*) = \arg \min_{\alpha, \beta} \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} |\alpha \mu_i + \beta - y_i|. \quad (19)$$

按题目规定，若校准后验证集分类指标不占优，则主口径不采用校准、仅列为敏感性分析。图 10 给出校准前后的强度散点对比，校准把收缩的预测两端幅度拉开，平均绝对误差略有下降，但分类指标未获得稳定收益，因此最终提交仍使用未校准的强度值，避免额外后处理改变主结果，校准结果仅用于说明收缩的来源。




图 10 强度校准前后对比

主模型的关键参数如表 5 所示，全部取值可对照配置文件与检查点元数据逐项复核。

表 5 问题二模型的数据、网络与训练参数

参数	取值	参数	取值
特征版本与序列长度	aligned, $T = 50$	隐维度	$d = 96$
缺失判定	有效区间内连续 ≥ 2 帧全零	门控专家数	$n_E = 2$
注意力	头数 4, 编码层数 2	轮数	教师 12, 学生 14
丢弃率与权重衰减	0.35, 5×10^{-4}	批大小与优化器	64, AdamW 配余弦退火
学习率	主干 5×10^{-5} , 头 5×10^{-4}	梯度裁剪与早停	1.0, 耐心 8 轮
输入噪声与整模态丢弃	0.15, 0.15	标签平滑与权重平均	0.1, 指数移动平均 0.99
缺失片段数与裁剪保留	每模态 1 至 3 段, 保留 0.7	位置先验	中 4/9, 头 3/9, 尾与随机各 1/9
辅助头	有序回归 $K = 10$, 权重 0.5	决策阈值	$\theta = 0.325$ (仅验证集拟合)

本章的设计与题目给定文献存在多处对应，也存在明确差异。动态专家门控与 EMOE 提出的模态专属动态情感专家 [17] 目标一致，不同的是我们的门控在输入中显式包含三模态缺失率与可用性统计；教师-学生蒸馏对应 CMAD 的模态感知蒸馏 [12]，我们额外把缺失类型与缺失率作为课程维度，并加入样本间关系蒸馏。与分解、重建、增强框架 [11] 相比，我们保留了共享-特有分解、但停用了重建项，关闭重建后验证集

误差由 0.5871 降至 0.5825，该负结果已在消融一节一并报告。处理缺失的另一类思路是生成式补全与代理任务，分别见于超图条件扩散 [10] 与 Proxy-Driven 方法 [13]；我们不做跨模态生成，而是以掩码参与注意力、缺失注入与对数方差头来达到同类目的。其余文献支撑本文的选题依据与稳健性动机 [9, 14, 16, 18]，多任务输出头的组织借鉴了多任务学习的设计 [3]。

5.4 结果分析与可视化

5.4.1 评价指标与评估口径

按赛题要求，情感极性采用准确率与 F1 值评价，情感强度采用平均绝对误差与皮尔逊相关系数评价，并补充 CCC 作为参考。记样本真值为 y_i 、预测值为 $\hat{y}_i$ ，类别真值与预测类别为 c_i 与 $\hat{c}_i$ ，四项指标定义为：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|, \quad r = \frac{\text{cov}(\hat{y}, y)}{\sigma_{\hat{y}} \sigma_y}, \quad (20)$$

$$\text{ACC} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\hat{c}_i = c_i], \quad F1_{\text{macro}} = \frac{1}{3} \sum_{k=1}^3 F1_k, \quad (21)$$

其中宏观 F1（Macro-F1）对三类样本等权计算（三类 F1 的算术平均），能够反映类别不平衡下中性类的识别问题，因此选作分类主指标；各类别 F1 与一致性指数 CCC 一并报告作为参考。各项指标的评估口径汇总于表 6。

表 6 评价指标与评估口径

项目	规定
主报集合	验证集（728 条）；测试划分（727 条）仅作泛化核验
极性主口径	分类头 argmax （与分类目标的直接口径）
极性对照口径	强度分数加单一对称阈值 θ （用于附件三一致性核验）
强度主指标	MAE 为主，皮尔逊相关系数为辅，CCC 参考
决策阈值	仅由验证集按宏观 F1 选定（ $\theta = 0.325$ ）
文献可比口径	二分类 Acc-2（分类头概率构造，负向对非负向）：0.8514（测试划分）
合规性	结构、超参数、阈值、后处理系数均只在验证集确定；附件三/四仅推理

需要先厘清两个易混淆的口径。我们把验证集作为主报集合，附件二测试划分只用于泛化核验；极性主口径采用分类头 argmax ，阈值口径仅用于一致性比较；模型结构、超参数、阈值与后处理系数均只依据验证集确定。附件二的测试划分含标签、可用于泛化核验，无标签的附件三测试集仅用于最终预测提交，二者性质不同，本章在表述上严格区分。另外，为便于与公开文献参照，本章额外计算了二分类 Acc-2 指标；由于公开设定的训练规模（约 16326 条）约为本章（3395 条）的 4.8 倍，该指标仅作量级参照，

不构成严格优劣比较。

5.4.2 基础性能评价

表 7 汇总提交模型在验证集与测试划分上的完整指标。验证集上（主报口径），MAE 为 0.5866、皮尔逊相关系数 0.6543、CCC 0.6278、准确率 0.6223、宏观 F1 0.6158；测试划分上 MAE 为 0.6216、ACC 为 0.6534、宏观 F1 为 0.6338。测试划分的分类指标与验证集相当或更高，MAE 略有增加，整体未出现明显失稳，说明模型未表现出明显过拟合。

表 7 问题二模型的基础性能

划分	MAE	Pearson	CCC	ACC	Macro-F1	中性类 F1
验证集（主报）	0.5866	0.6543	0.6278	0.6223	0.6158	0.5056
测试划分（核验）	0.6216	0.6807	0.6515	0.6534	0.6338	0.4656

图 11 的强度散点图（横轴为真值、纵轴为预测，颜色区分真值极性）显示，预测总体方向正确，但高强度的正负样本都存在向零收缩。分组偏差（预测减真值）分别为负类 +0.541、正类 -0.447、中性类 +0.110，说明强情感样本的幅值被系统性压缩，这是逐点回归损失下条件均值解的固有现象，也是本章强度误差的首要来源。




图 11 强度预测值与真值散点图（验证集）

图 12 的三分类混淆矩阵（行、列分别为真值与预测类别）进一步显示，中性类是当前分类性能的主要短板：184 条真中性样本中有 72 条被判为极性样本，同时有 147 条

极性样本被判为中性，双向混淆明显，中性类精确率仅为 0.4324；相比之下，负类和正类的区分更稳定。非对角元还给出了错判的方向与规模，中性边界由此可确认是当前模型的主要误差来源。




图 12 三分类混淆矩阵（验证集；左为计数、右为行归一化）

图 13 的绝对误差直方图显示误差呈长尾分布，多数样本的误差小于 0.5，少数强情感样本超过 2.0，而平均误差的量级正是由这些长尾样本主导；分位统计与此一致，绝对误差的 90 分位约为中位数的三倍。




图 13 强度绝对误差的分布（验证集；左为总体分布、右为按真值极性的分层）

为衡量所提模型的水平，表 8 给出与公开结果的量级对照。需要强调两点前提。文献几乎一律主报二分类 Acc-2（负向对非负向），与题目要求的三分类 ACC 不可直接并列；且公开 CMU-MOSEI[1] 划分的训练样本为 16326 条，约为赛题的 4.8 倍。按统一复现口径，公开基线的三分类准确率为 0.661 至 0.676、平均绝对误差为 0.526 至 0.601、皮尔逊相关为 0.683 至 0.778；本文对应为 0.6223、0.5866 与 0.6543。二分类口径 0.8514 落在公开干净设定区间（约 0.84 至 0.86）之内，明显高于随机缺失协议下的公开水平（约 0.71 至 0.79）。在约五分之一训练规模下达到公开量级，说明特征组织与融合设计是有效的；由于训练规模与评价口径的差异，上述对照仅作量级参照，不作严格优劣比较。

表 8 与公开结果的量级对照（口径已对齐说明）

方法	训练规模	模态设定	缺失设定	Acc-2
公开基线（文献常报区间）	16326	三模态	全模态干净	0.84 至 0.86
公开基线（随机缺失协议）	16326	三模态	随机缺失	0.71 至 0.79
本文 MRF-Net（测试划分）	3395	三模态	全模态干净	0.8514

注：本表仅作量级参照；公开区间按统一复现口径从相关文献汇总，其训练规模与评价协议与本题并不一致，具体来源见参考文献对应条目。

5.4.3 缺失模态类型、位置与时长的影响规律

为系统分析局部缺失对性能的影响，本章把缺失类型、缺失位置与缺失率的组合枚举成一张场景网格，缺失类型 6 种（仅文本、仅语音、仅视觉、文本 + 语音、语音 + 视觉、三模态全缺）、缺失位置 4 种（头部、中部、尾部、随机）、缺失率 5 档（0.1 至 1.0），合计 120 个场景，设计如表 9 所示。缺失率按式 (1) 定义，即缺失帧数占该模态有效长度的比例；不直接以绝对帧数分档，是因为三种模态的有效长度差异很大（文本恒为 50 帧，语音与视觉约 24.6 与 23.8 帧），同一绝对档位在不同模态与样本上对应的缺失比例可相差数倍。扫描在验证集上进行，每个场景对全部 728 条样本注入相同的缺失结构并计算指标；由于头部、中部、尾部三种位置的掩码是确定性的，扫描采用单次确定性评估，统计推断以三因素方差分析中的最高阶交互作为误差项，证据以效应量（ η^2 ）与实际差值为主、显著性检验为辅。

表 9 缺失规律扫描的实验设计

因素	水平
缺失类型	仅文本 / 仅语音 / 仅视觉 / 文本 + 语音 / 语音 + 视觉 / 三模态全缺（6 类）
缺失位置	头部 / 中部 / 尾部 / 随机（4 类）
缺失率	0.1 / 0.2 / 0.3 / 0.5（另含整模态 1.0 的极限情形）
组合规模	$6 \times 4 \times 5 = 120$ 种场景

性能退化量定义为相对无缺失基线的差值：

$$\Delta \text{MAE}(\tau, p, \rho) = \text{MAE}(\tau, p, \rho) - \text{MAE}_{\text{clean}}, \quad \Delta \text{ACC} = \text{ACC}(\tau, p, \rho) - \text{ACC}_{\text{clean}}. \quad (22)$$

图 14 的左、右面板分别给出六类缺失下验证集 MAE 与宏观 F1 随缺失率的退化曲线（虚线为无缺失基线）；结果表明，性能退化主要由文本缺失驱动。在 MAE 侧，文本

缺失在缺失率 0.1 至 0.2 时几乎无影响，从 0.3 起明显抬升，到整模态缺失 ($\rho = 1.0$) 时增量达到 +0.1804；语音缺失与视觉缺失即使整模态完全不可用，增量也仅为 +0.0002 与 +0.0068，含文本的混合缺失（文本 + 语音）与文本单缺几乎重合（+0.1810）。一个例外是三模态全缺，其增量升至 +0.1950，比仅文本缺失再高出约 8%，说明保留可见的语音与视觉仍能贡献少量互补信息；该极端情形在训练注入中并不会出现（训练始终保留至少一个可见模态），模型对它承担的属于分布外的下界损失。整模态缺失时，文本造成的误差增量约为视听模态的 25 倍，情感判别由文本主导，鲁棒性设计应以文本分支为重点。




图 14 六类缺失下的退化曲线（左：验证集 MAE；右：宏观 F1；虚线为无缺失基线）

图 14(b) 从分类指标侧给出同一规律的镜像证据，文本缺失使宏观 F1 持续下降且降幅随缺失率放大，整模态缺失时降幅达 0.3038（三模态全缺为 0.3587）；语音与视觉缺失的 F1 曲线仅在噪声范围内波动（降幅不超过 0.007）。两个指标趋势一致，说明文本主导的规律不是单一指标的偶然现象。

图 15 把六类缺失的退化量按缺失率汇总成综合视图（散点为各类退化量、折线为六类均值、阴影为极差范围），随着缺失率上升，退化谱整体右移，文本类始终占据分布的上缘；在缺失率 0.5 处，文本类与视听类的差距已拉开到约 10 倍（+0.031 以上对 +0.003 以下）。综合视图说明退化的主导因素在全部扫描范围内保持稳定。




图 15 六类缺失的综合退化视图（散点为各类退化量、折线为六类均值、阴影为极差）

缺失位置同样存在稳定差异。图 16 给出类型与位置的平均退化热力图（对五档缺失率取平均，含整模态档），图上两个结构一目了然，文本相关类型的退化比视听类型高一个量级（约 $+0.04$ 至 $+0.05$ 对 $+0.003$ 以下），且同一类型内头部缺失最重、中部最轻（仅文本一行头部较中部多约 $+0.007$ ）。若剔除整模态档、只在部分缺失范围内统计（表 10），位置次序保持不变，头部缺失的平均退化最大（ $+0.0078$ ），其后依次为随机（ $+0.0052$ ）、尾部（ $+0.0039$ ）与中部（ $+0.0035$ ）；在文本模态上，头部与中部之差达到 2.7 倍（ $+0.0141$ 对 $+0.0052$ ）。可能的解释是，文本特征的开头往往承载话题与情感倾向的定调信息，缺失头部意味着丢失上下文起点，模型需要更强的推理能力才能补全；而中部或尾部缺失时，已见片段通常足以恢复大部分语义。两个朴素基线在四个位置上的退化几乎持平（ 0.0102 至 0.0137 ），未表现出明显的位置结构；MRF-Net 的残余退化则呈现头部最重的稳定次序，说明掩码感知设计利用了缺失位置信息。图 16(b) 的宏观 F1 热力图与 MAE 维度的结构同构，位置结论在两个指标上一致。




图 16 缺失类型 $\times$ 缺失位置的平均退化热力图（左： ΔMAE ；右： $\Delta\text{宏观 F1}$ ；对五档缺失率取平均，含整模态档）

表 10 各模型在四个缺失位置上的平均 MAE 增量

缺失位置	A0 朴素融合	A1 加掩码指示	MRF-Net 单种子	MRF-Net 集成
头部	0.0120	0.0133	0.0063	0.0078
中部	0.0102	0.0118	0.0022	0.0035
尾部	0.0128	0.0132	0.0031	0.0039
随机	0.0121	0.0137	0.0038	0.0052

三因素方差分析进一步量化了上述规律。表 11 以退化量为响应做方差分析，报告效应量 η^2 （误差项取最高阶交互）：

$$\Delta\text{MAE} \sim C(\tau) * C(p) * C(\rho), \quad (23)$$

其中 $C(\cdot)$ 表示按类别变量处理。基线模型中缺失类型与缺失率交互的效应量高达 0.9517，意味着退化几乎完全取决于缺失的模式与比例；在 MRF-Net 集成模型上该效应量降至 0.8415，说明缺失感知设计削弱了退化对缺失结构的依赖，退化被整体摊平。与之相对，缺失类型与缺失位置交互的效应量从基线的 0.0053 提升至 0.0614（约 12 倍），即 MRF-Net 对缺失位置变得敏感，这是掩码与位置信息被模型利用的间接证据。按位置统计，MRF-Net 将退化量相对朴素基线降低约 1.5 至 3.3 倍（头部 1.5 倍、中部 2.9 倍、尾部 3.3 倍、随机 2.3 倍），其中头部场景收益最小，与头部缺失本身伤害最大相符。

表 11 三因素方差分析的效应量（ η^2 ，响应为 MAE 增量）

效应项	A0 朴素融合	A1 加掩码指示	MRF-Net 单种子	MRF-Net 集成
缺失类型 $\times$ 缺失率	0.9517	0.9426	0.8772	0.8415
缺失类型 $\times$ 缺失位置	0.0053	0.0033	0.0445	0.0614
缺失位置 $\times$ 缺失率	0.0025	0.0026	0.0273	0.0288
缺失类型（主效应）	0.0094	0.0132	0.0007	0.0081
缺失位置（主效应）	0.0002	0.0005	0.0034	0.0041
缺失率（主效应）	0.0004	0.0004	0.0041	0.0053

为量化所提方案相对基线的收益，本章把四个模型放在同一退化扫描协议下对比，结果见图 17（左、右图分别为 MAE 与准确率的增量，虚线为零基准）。两个朴素融合基线代表不做缺失处理的常规做法，另两条为本文模型的单种子与集成版本。MRF-Net 的曲线全程位于两个朴素基线下方，且在高缺失率区间差距扩大。




图 17 四个模型在缺失场景下的性能对比

由于三个模态的有效长度不同（文本 50 帧，语音约 24.6 帧、视觉约 23.8 帧），同一缺失率下文本损失的绝对帧数约为另两者的两倍。为排除该口径差异的干扰，本章进一步在匹配绝对缺失帧数的条件下重做对比，在均缺失约 25 帧的匹配组上，文本、语音、视觉的 MAE 增量分别为 +0.0314、+0.0002 与 +0.0068，文本仍是语音的约 170 倍；在约 5 帧的小缺失匹配组上（文本 0.1、语音 0.2、视觉 0.2），三维增量为 -0.0016、+0.0001、+0.0010，均接近零。这说明，文本缺失主导性能退化这一结论不依赖缺失率定义本身。

5.4.4 消融实验与超参数搜索

为保证差值可比，消融实验采用同种子、同基准配方、单开关翻转的配对设计，以种子 42 的基准配方（MAE 0.5871、宏观 F1 0.5857）为参照，每次只关闭一个模块；同时用基准配方在种子 42 与 43 上的表现差（MAE 极差 0.0095、宏观 F1 极差 0.0092）作为种子噪声标尺，若模块的消融幅度小于种子极差，则该模块的单独效应不可辨识。

表 12 同种子配对消融实验结果（验证集）

配置	种子数	MAE	宏观 F1	ΔMAE	Δ 宏观 F1
基准配方（种子 42，配对基准）	1	0.5871	0.5857	—	—
基准配方（种子 43）	1	0.5967	0.5765	—	—
基准配方两种子极差	2	—	—	0.0095	0.0092
去除掩码指示	3	0.5866	0.5913	-0.0005	+0.0056
去除跨模态重建	1	0.5825	0.5868	-0.0047	+0.0011
单专家（去动态门控）	1	0.5942	0.5733	+0.0070	-0.0124
去除教师蒸馏	1	0.5913	0.5787	+0.0042	-0.0070
去除缺失课程学习	1	0.5885	0.5898	+0.0013	+0.0041
朴素融合（无缺失处理）	1	0.6010	0.5932	—	—
朴素融合加掩码指示与缺失注入	1	0.5990	0.5782	—	—
主模型（2 种子集成，最终配方）	2	0.5866	0.6158	—	—

表 12 给出四条关键证据。（1）所有模块级消融的 MAE 幅度（最大 0.0070）都小于基准配方自身的种子极差 0.0095，即单模块效应比种子抖动还小，说明任何单一模块

都不足以单独解释性能来源；（2）宏观 F1 上仅动态专家门控退化为单专家一项略超种子极差（0.0124 对 0.0092，约 1.35 倍）且双指标同向劣化，是全部模块中最接近可判定的一项；（3）去除跨模态重建使双指标同时改善，与最终配方关闭重建的设计决定一致；（4）最稳健的证据来自朴素融合基线，其 MAE 比基准配方高出 0.0139 与 0.0119，双双超过种子极差，而所有模块级消融均未达到这一幅度。上述证据指向同一结论，即性能来源是缺失检测、掩码参与注意力、缺失注入训练与门控融合的整体配合，无法归因到某个可单独摘除的模块。作为并列参照，主模型的宏观 F1 比基准配方高 0.0301，但其相对基准同时改动了多项（关闭重建、引入有序回归辅助头与弱标注加权、调整轮数并启用权重平均），因此不把该提升归因于任何单项。图 18 以双面板发散条形图呈现各模块效应量与种子噪声带的相对关系，左、右面板分别为 ΔMAE 与 $\Delta\text{Macro-F1}$ ，灰色竖带为基准配方两种子的极差范围，灰色斜纹条为并列参照的朴素融合基线。




图 18 消融实验对比（左： ΔMAE ；右： $\Delta\text{Macro-F1}$ ）

超参数经两阶段搜索确定，先在 1024 条训练子集上快速筛选 4 组候选，再用全量训练集复跑入选配置。表 13 与图 19（哑铃图每行一个候选、左右端点为两阶段指标）汇总了两阶段的结果，宏观 F1 的排名完全一致（秩相关 +1.00），而 MAE 的排名出现反转（秩相关 -0.40），筛选阶段误差最低的隐维度 128 配置在全量训练后成为误差最高者，说明小样本快速筛选对回归误差的排序稳定性有限。以单种子噪声（MAE 标准差 0.0060、宏观 F1 标准差 0.0083）为基准核验后发现，隐维度由 96 增至 128 使 MAE 恶化 +0.0201 ($z = 2.37$)、宏观 F1 下降 -0.0362 ($z = -3.07$)，是唯一显著的差异，且为显著劣化；蒸馏权重 0.3 到 0.5 与丢弃率 0.35 到 0.50 的差异均落在噪声内 ($|z| < 0.7$)，不构成有效改进。由此，本章的结论是当前容量已经足够、不应继续加宽网络；除隐维度不加大外，不宣称任何调参收益。




图 19 超参数搜索两阶段对比（哑铃图）

表 13 超参数搜索两阶段的显著性检验

候选	Δ MAE	z	Δ 宏观 F1	z	判定
蒸馏权重 0.3 到 0.5	-0.0055	-0.65	+0.0026	+0.22	不显著
丢弃率 0.35 到 0.50	+0.0054	+0.64	-0.0075	-0.64	不显著
隐维度 96 到 128	+0.0201	+2.37	-0.0362	-3.07	显著劣化
单种子噪声（参考）	0.0060	—	0.0083	—	噪声基准

5.4.5 错误归因与不确定性分析

分层误差分析表明，分类与回归的困难来自不同样本。表 14 与图 20 从强度幅值、文本长度、视觉长度、真值极性、是否含缺失五个维度对验证集误差分层（图中柱高为 MAE、折线为分类准确率）。

强度绝对值不超过 0.5 的弱情感样本占验证集 45.5%（331/728），其强度预测较准（MAE 0.402，全桶最低），但分类准确率只有 0.5045，主要困难集中在零点附近的极性边界，这与中性类 F1 偏低的结论一致；相反， $|y| > 1.5$ 的强情感样本分类较容易，MAE 却达到 1.080（为弱强度桶的 2.7 倍），说明回归误差主要来自强度幅值。含缺失的 48 条验证样本分类准确率为 0.5208，低于无缺失样本的 0.6294，但由于样本量较小，该差异只能作为趋势性证据。文本长度与视觉长度的影响方向不同，中等长度文本的分类准确率最低（0.583），而视觉有效长度从短到长时 MAE 单调上升（0.492 至 0.669），说明视觉时长主要影响强度回归。

表 14 五维分层错误归因（验证集， $n = 728$ ）

维度	分组	样本数	MAE	分类准确率
强度幅值	$ y \leq 0.5$	331	0.402	0.5045
	$0.5 < y \leq 1.5$	267	0.575	0.6592
	$ y > 1.5$	130	1.080	0.8462
文本长度	短 / 中 / 长	243 / 242 / 243	0.497 / 0.606 / 0.657	0.6173 / 0.5826 / 0.6667
视觉长度	短 / 中 / 长	243 / 242 / 243	0.492 / 0.599 / 0.669	0.6214 / 0.5868 / 0.6584
真值极性	负向 / 中性 / 正向	206 / 184 / 338	0.748 / 0.383 / 0.599	0.6408 / 0.6087 / 0.6183
是否含缺失	含缺失 / 无缺失	48 / 680	0.518 / 0.591	0.5208 / 0.6294




图 20 五维分层错误归因

结合转写文本对误差最大的 20 条样本逐条判读，可将主要失败归纳为五类模式（表 15），其中前三类覆盖了约七成极端误差。（1）强度系统性压缩（数量最多），例如某样本的转写为 “This movie was excellent”，真值强度 +3.0，模型仅给出 +0.63；另一例 “it should be rated junk”，真值 -3.0，模型给出 -0.62，强烈情感词只被赋予约五分之一的幅度，与前述偏差统计一致。（2）转折与否定结构导致极性反转：样本 “But it’s not as bad as I thought it would be”（真值 +1.0）被判为强负（-2.23），“Very long movie but, the time flies by, absolutely fantastic”（真值 +2.67）被压至 -0.83，转写经聚合后从句的极性反转被抹平，否定词的作用域未被显式建模。（3）口语转写噪声干扰：“I’m giving this beast a four out of, (stutter) I mean, (uhh) wait, four, no”（真值 +1.0）被判为 -1.23，填充词与自我纠正使情感信号不稳定。其余两类属于含蓄表达（需语用推理）与语境残缺或标注存疑，可改进空间有限。

表 15 失败模式汇总（基于验证集/测试划分各 20 条极端误差判读）

失败模式	验证集	测试划分	机制	可改进性
F1 强度系统性压缩	7/20	8/20	条件均值收缩	高
F2 转折/否定反转	5/20	3/20	否定作用域未建模	较高
F3 含蓄/隐含评价	4/20	4/20	缺乏语用推理	一般
F4 口语转写噪声	3/20	3/20	填充词污染表示	高（低成本）
F5 语境残缺/标注噪声	4/20	5/20	数据固有	低

对 20 条最大误差样本的缺失状态统计显示，验证集 20 条均不含缺失，测试划分中也有 17/20 不含缺失。这一现象反过来支持了本章的鲁棒性设计，在现有鲁棒训练下，局部缺失已不再是主要误差来源，语义理解与语用推理才是当前性能的瓶颈；这也解释了消融一节得到的结论。稳健性来自整体配合，而提高上限的方向在表征层，不在缺失处理层。

在基础预测之外，模型还能给出逐样本的不确定度。利用强度回归头的方差输出（偶然不确定度）与两个种子成员之间的分歧（认知不确定度）可以构造总不确定度；分类头概率的熵则刻画极性判别的不确定度。图 21 给出强度回归的风险—覆盖率曲线（黑线为按不确定度剔除、灰虚线为随机剔除），按总不确定度排序剔除样本时，平均绝对误差由 0.5866 降至 0.5465（剔除最不确定的 10% 样本），剔除 50% 后降至 0.4495，曲线下面积（AURC）为 0.4365。图 22 给出极性判别的拒识效果，按分类熵剔除最不确定的 50% 样本后，极性准确率由 0.6223 提升至 0.7637（测试划分 0.8214）。图 23 进一步给出总不确定度与绝对误差的散点关系（斯皮尔曼相关 0.296 与 0.230，验证与测试划分均为正）。两个不确定度并不通用，总不确定度对极性拒识无效（其 AURC 劣于随机），分类熵对强度回归无信息，强度与极性必须分别使用各自的不确定度做拒识，模型因此能够对自身不可靠的判断给出提示。




图 21 强度回归的风险—覆盖率曲线




图 22 拒识对极性准确率的影响




图 23 总不确定度与绝对误差的关系（验证集）

5.4.6 附件三测试集预测结果汇总与展示

附件三共 30 条无标签样本，其缺失为实测结构（表 4），语音 17 条、视觉 18 条含缺失，缺失率均值分别约 0.10 与 0.11，文本无缺失。推理使用 5.3.5 节确定的双种子集成（种子 42 与 43）与决策阈值 $\theta = 0.325$ ，输出极性标签、强度分数、三类概率、置信度与三模态缺失统计。

表 16 与图 24、图 25 给出全量预测的构成与分布（构成图左为极性条数、右为强度与置信度；分布图中虚线为判定阈值）。30 条样本的预测结果为负向 6 条、中性 14 条、正向 10 条；全样本平均强度 +0.2451，平均绝对强度 0.4930，平均置信度 0.5840。按实测缺失状态分组，两组的平均强度拉开差距，含缺失组（18 条）为 +0.1949，低于无缺失组（+0.3204）；但两组的平均绝对强度（0.4304 对 0.5869）与平均置信度（0.5738 对 0.5993）差距不大。这表明缺失样本的预测更接近中性，但模型置信度没有出现异常下降。由于附件三没有标签，这里只能描述输出分布，不能据此判断缺失组的预测更准确或更稳定。预测强度集中于 -1.2 至 1.5、置信度分布于 0.44 至 0.91 之间，分布无异常值。

表 16 附件三测试集的全量预测汇总

指标	全样本	含缺失	无缺失
样本数	30	18	12
预测负向	6	4	2
预测中性	14	10	4
预测正向	10	4	6
平均强度	+0.2451	+0.1949	+0.3204
平均绝对强度	0.4930	0.4304	0.5869
平均置信度	0.5840	0.5738	0.5993
两口径一致率	0.8333	—	—




图 24 附件三预测结果构成（全样本 / 含缺失 / 无缺失）




图 25 附件三预测强度与置信度分布

为直观展示缺失结构如何作用于单条样本，图 26 选取两条代表性样本给出逐帧缺失时间线与预测输出。两条样本的语音与视觉缺失区间完全同步（源于同一视频流的分段丢失），文本流完整。附件 3_26 缺失 4/22 帧（18.2%），集中在头部与中部两段，模

型仍以 0.76 的概率判为正向；附件 3_30 缺失达 10/25 帧（40.0%）、跨越头、中、尾三段，预测强度降为 -0.11、负向概率仅 0.45，输出明显向中性收缩，缺失越深、判断越保守，与表 16 的组间对比一致。




图 26 附件三代表性样本的缺失时间线与预测卡（上：附件 3_26；下：附件 3_30）

提交文件 pred_att3.csv 共 15 个字段，覆盖判定结果、概率、置信度、阈值与缺失统计，便于复核（表 17）。为核验口径稳健性，同时计算了分类头口径与阈值口径两种判别结果，二者的一致率为 0.8333；两种口径的差异集中在强度分数接近阈值的中性边界样本上，与错误归因一节的边界困难结论一致。预测结果之外，还需交代两个专项测试集本身的输入条件，按式 (1) 逐一统计可见，附件三语音与视觉模态的含缺失样本比例分别为 56.7% 与 60.0%，平均实测缺失率约 0.10，且以短碎片形式出现；文本模态在三套数据中均无实测缺失，附件四有 1 条样本视觉模态整条缺失。附件三的文本鲁棒性因此无法直接验证，只能依靠训练期的文本缺失注入兜底，本文在 5.5 节一并说明。

表 17 提交文件主要字段说明

字段	含义
id	样本编号（附件 3_01 至附件 3_30）
pred_label / pred_label_theta	分类头口径 / 阈值口径的极性判定
pred_score / prob_neg, prob_neu, prob_pos	情感强度分数 / 三分类概率
confidence / confidence_theta / theta	置信度 / 阈值口径置信度 / 所用阈值（0.325）
missing_text_ratio 等三列	三模态实测缺失率（与 5.2 节口径同源）
n_missing_intervals	缺失区间段数

5.5 本章小结

本章针对局部模态缺失建立了 MRF-Net，并在统一缺失口径下完成了鲁棒性建模、缺失规律扫描、消融验证和附件三推理。数据层面，尾部填充与有效区间内缺失必须分开统计；由于附件二真实缺失极少，训练阶段需要主动注入缺失。模型层面，掩码感知编码、动态专家门控和课程式缺失训练共同构成鲁棒框架，消融结果更支持整体框架的有效性，而非单模块的决定作用。

规律分析显示，性能退化主要由文本缺失驱动，并且头部缺失的影响大于中部和尾部。MRF-Net 将缺失类型与缺失率交互的效应量由 0.9517 降至 0.8415，不同缺失位置下的平均退化较朴素基线降低约 1.5 至 3.3 倍。最终模型在验证集上取得 MAE 0.5866、Pearson 0.6543、ACC 0.6223 和 Macro-F1 0.6158；附件三的 30 条预测已按统一格式提交，预测分布为负/中/正 = 6/14/10。

本章仍有两点限制。附件三和附件四都没有文本真实缺失，文本分支的鲁棒性主要依赖模拟注入验证；验证集中含缺失样本只有 48 条，部分统计结果的不确定性较大，且注入缺失率（模拟口径）与实测缺失率（附件三口径）语义不同，全章已分别标注。验证集同时承担早停、阈值选择和部分归因分析，可能带来轻微乐观偏差，因此测试划分只作为最终泛化核验，不再参与模型选择；文本鲁棒性问题将结合问题三的可解释性框架进一步分析。

六、问题三模型的建立与求解

6.1 问题分析

问题三不再只关注预测是否正确，而是要求说明预测依据，即三种模态分别起多大作用、模型主要依赖哪一种模态、每个模态中哪些局部片段与最终判断关系最密切；关键证据还需要回到原始文本、语音时段或视频关键帧，保证可以人工复核。解释结论需与预测结果一并提交。解释本身也必须经得起检验，因为解释不可信时，模型的判断依据就无从核验。

综合上述要求，本问的求解可以拆分为四个环节。从骨干冻结与解释头训练开始，直接沿用问题二的骨干并冻结全部参数，在其上并联一个轻量证据头，以忠实性与充分性为训练目标；冻结骨干保证问题三的预测与问题二逐位一致，解释头不接入预测通路，训练解释不会影响预测结果。随后计算三层解释，模态级用精确枚举的 Shapley 值量化各模态作用度，片段级用积分梯度与遮挡分析定位关键区段，证据级用反事实删除把重要性落到具体词片段、秒区间与关键帧；博弈论、梯度与遮挡三类方法互相独立，结论可以交叉核验。进而完成融合与权重标定，三源重要性按验证集上与遮挡基准一致性最大的准则确定融合权重，使解释以模型无关方法为锚。而后进行质量评估与证据回填，用忠实性、充分性、稀疏性与稳定性四项指标评估解释质量，并通过删模态退化一致性

与附件三免标注检验验证机制，把重要片段回映到原文词句、语音时段与视频关键帧，得到解释卡与附件四的提交文件。整体求解流程如图 27 所示。




图 27 问题三的求解流程

6.2 模型建立

6.2.1 可解释性的形式化定义与方案选择

设骨干网络 f 将三模态输入 $\mathbf{X} = (\mathbf{X}^t, \mathbf{X}^a, \mathbf{X}^v)$ 映射为强度预测 $\hat{y}$ 与极性概率 $\hat{p}$ 。对每个样本，解释输出包括三部分，即三模态作用度向量、主要参考模态，以及每个模态 50 个时间步的重要性向量；可解释性要求同时给出三个层次的量化结果：

$$\boldsymbol{\pi} = (\pi_t, \pi_a, \pi_v), \quad \sum_{m \in \mathcal{M}} \pi_m = 1, \quad m^* = \arg \max_m \pi_m, \quad \mathbf{w}^m \in \mathbb{R}_{\geq 0}^T, \quad (24)$$

式中 π_m 为模态 m 对本样本预测的作用程度， m^* 为主要参考模态， $\mathbf{w}^m$ 为模态 m 内各时间步 ($T = 50$) 的重要性向量。题目要求解释结果可量化、可复核，因此我们没有直接把模型内部注意力当作解释结果，而是要求每一项解释都能通过独立实验验证。

图 28 勾勒本问的解释路线，模态级用 Shapley 值计算作用度向量 $\boldsymbol{\pi}$ ，衡量各模态对预测的贡献；片段级用积分梯度与证据头刻画时间重要性 $\mathbf{w}^m$ ，定位关键的区段；证据级用反事实删除与遮挡把重要性落到可回填的词片段、秒区间与关键帧。三路结果汇入

同一张解释卡，再经一致性校验与免标注机制检验。




图 28 三层解释通路示意

可选的解释路线有三类，对比如表 18 所示。注意力权重来自模型内部、计算零成本，但其大小受缩放方式、层数与头数影响，已有研究指出注意力与真实重要性不一致的反例，故仅作为对照基线；代理模型需要额外的近似采样，解释方差不可控；精确 Shapley 在模态数仅为三时可对全部 2^3 个子集精确枚举，不存在近似误差，再配合积分梯度与遮挡，就构成了公理化、细粒度与模型无关的三重校验。

表 18 可解释性方案候选对比

候选	方法族	主要不足	是否采用
注意力权重	模型内生	注意力与重要性的对应关系无公理化保证	仅作基线
代理模型近似	模型无关近似	需采样近似，结果随随机种子波动	否
Shapley+ 积分梯度 + 遮挡	博弈论/梯度/遮挡	需多次前向（本任务算力可承受）	采用

选定该组合的量化依据见 6.3.3 小节。实测中，注意力权重与遮挡结果的秩相关仅为 -0.0268 ，说明直接以注意力权重作解释在本模型上并不成立；改用三源融合后，与遮挡基准的一致性达到 0.9561 ，因此最终采用后者。

本问与题目给定文献存在如下对应与差异。Locate-and-Explain[15] 面向会话级情绪原因抽取与摘要，输出自然语言摘要，我们输出的是可量化、可复核的字符区间与秒区间，粒度更细且可直接回填提交文件；不确定性感知的生成式方法 [10] 关注缺失下的可信预测，我们把不确定度用于解释质量的稳健性核验；因果不变性视角 [14] 与本文关于注意力不等于重要性的实证呼应，说明解释方法需经外部基准校验；知识蒸馏与动态调整 [18] 作用于骨干训练期，与本文解释头不接入预测通路的设计互补。

6.2.2 可解释性证据头的结构与目标函数

为了让解释本身可训练，本文在冻结骨干上并联一个轻量证据头。记骨干第 m 个模态编码器的输出为 $\mathbf{H}^m \in \mathbb{R}^{T \times d}$ (d 为隐维度)，证据头先给出有效时间步上的证据分布：

$$s_k^m = \frac{\exp(\mathbf{w}_m^\top \tanh(\mathbf{W}_m \mathbf{h}_k^m + \mathbf{b}_m))}{\sum_{k' \in \mathcal{V}^m} \exp(\mathbf{w}_m^\top \tanh(\mathbf{W}_m \mathbf{h}_{k'}^m + \mathbf{b}_m))}, \quad k \in \mathcal{V}^m, \quad (25)$$

式中： $\mathbf{h}_k^m$ 为第 k 个时间步的表示， $\mathcal{V}^m$ 为该样本模态 m 的有效时间步集合，分母限制在有效位内求和，使填充位不参与证据分配； s_k^m 即片段级重要性的可训练形式。再以证据加权的模态表示汇总为模态作用度：

$$\bar{\mathbf{h}}^m = \sum_{k \in \mathcal{V}^m} s_k^m \mathbf{h}_k^m, \quad \boldsymbol{\pi} = \text{softmax}\left((\mathbf{u}^\top \tanh(\mathbf{V} \bar{\mathbf{h}}^m))_{m \in \mathcal{M}}\right). \quad (26)$$

证据头不接入预测通路，因此式 (26) 的 $\boldsymbol{\pi}$ 不影响 $\hat{y}$ 与 $\hat{\mathbf{p}}$ ，问题三的预测与问题二逐位一致。训练目标是让 $\mathbf{s}$ 与 $\boldsymbol{\pi}$ 忠实于骨干的真实决策依据。记 $t(X)$ 为骨干的强度输出， $X^{\setminus s}$ 表示把模态 m 的缺失指示置为 s^m 后得到的输入 (s^m 越大表示该段越应被移除)， $X^{\cap s}$ 表示只保留 s^m 加权的信息，则损失函数为：

$$\mathcal{L} = \alpha_f \left[- (t(X) - t(X^{\setminus s}))^2 + (t(X) - t(X^{\cap s}))^2 \right] + \alpha_1 \sum_m \|\mathbf{s}^m\|_1 + \alpha_2 \sum_m \text{TV}(\mathbf{s}^m), \quad (27)$$

式中第一项为忠实性项，按 $\mathbf{s}$ 移除信息后预测变化越大越好；第二项为充分性项，只保留 $\mathbf{s}$ 加权信息时应尽量接近全模态预测；第三项为稀疏项，鼓励证据聚焦；第四项为时间全变差项，抑制证据在相邻时间步之间剧烈跳变， $\text{TV}(\mathbf{s}^m) = \sum_k |s_{k+1}^m - s_k^m|$ 。由于缺失指示在编码器内以实数参与运算，式 (27) 对 $\mathbf{s}$ 可微，可用反向传播直接优化。关键参数取 $\alpha_f = 1$ 、 $\alpha_1 = 10^{-3}$ 、 $\alpha_2 = 10^{-3}$ ，在验证集上以忠实性减充分性偏差作为选择目标；优化器为 AdamW，学习率 10^{-3} ，批量 64，训练 12 轮并按验证目标早停，骨干权重全程冻结。该目标值由首轮的 -0.6503 提升到最优轮（第 11 轮）的 -0.6103 ，证据头参数量约 9 万，保存于支撑材料的 runs/q3/q3_evidence_head.pt。

6.2.3 模态级与片段级解释的计算

把模态集合记为 $\mathcal{M} = \{t, a, v\}$ ，对任一子集 $S \subseteq \mathcal{M}$ ，定义效用 $v(S)$ 为仅使用 S 中模态时模型的目标标量（以强度 $\hat{y}$ 为主口径，极性概率为对照），模态 m 的 Shapley 值为：

$$\varphi_m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|! (3 - |S| - 1)!}{3!} [v(S \cup \{m\}) - v(S)]. \quad (28)$$

因模态数仅为 3，式 (28) 只需枚举 $2^3 = 8$ 个子集即可精确求得，没有近似误差。逐样本回代即得样本级 φ_m ；把 $v(S)$ 取为验证集上的负平均绝对误差或宏观 F1，即得数据集级的模态重要性。实现时使用效率公理进行自检：验证 $\sum_m \varphi_m = v(\mathcal{M}) - v(\emptyset)$ ，全部样本的残差不超过 10^{-15} 。

图 29 以格图示意枚举过程，从空集出发沿加入一个模态的边逐层到达全集，每条边的增量是一次边际增益 $F(S \cup \{i\}) - F(S)$ ；同一模态在全部路径上的边际增益按组合权重取平均，即式 (28)。 $n = 3$ 时全部子集与边际增益都可精确计算，无需任何采样近似。




图 29 三模态 Shapley 值枚举示意

屏蔽某模态时，本文把该模态所有有效位置的缺失指示置 1，即使用模型在训练期见过的整模态不可用语义；作为对照，另算把该模态整段置为填充（完全不可见）的口径。由于效用函数并非恒正， φ 可能出现全负（表示该模态相对无信息先验起抑制作用），因此采用两种归一化，两种口径都会报告，并以与真实删模态退化的秩相关择优（见 6.3.3 小节）：

$$\pi_m^{\text{relu}} = \frac{\max(\varphi_m, 0)}{\sum_{m'} \max(\varphi_{m'}, 0) + \epsilon}, \quad \pi_m^{\text{soft}} = \frac{\exp|\varphi_m|}{\sum_{m'} \exp|\varphi_{m'}|}. \quad (29)$$

屏蔽语义与效用目标是否影响结论，也做了对照检验，把屏蔽由缺失指示置 1 改为整段置为填充后，两组 φ 的秩相关为 0.5782；把效用由强度目标换为极性概率目标后，与强度口径的秩相关为 0.9758。可见，模态级排序对效用定义高度稳健，对屏蔽语义仅中等稳健；两种语义分别对应模态不可用与模态不可见两类现实场景，本文明确以不可用为主口径。

片段级重要性来自三个互补的来源：模型内生注意力 $\mathbf{w}^{\text{att}}$ 、积分梯度 $\mathbf{w}^{\text{ig}}$ 与遮挡 $\mathbf{w}^{\text{occ}}$ 。其中积分梯度以训练集均值特征为基线（归一化空间中即零向量），逐点累计梯度得到每个时间步的重要性：

$$\mathbf{w}_k^{\text{ig}} = \left\| (\mathbf{X}_k^m - \mathbf{X}_k^{\prime m}) \odot \frac{1}{L} \sum_{l=1}^L \nabla_{\mathbf{X}_k^m} t\left(\mathbf{X}' + \frac{l}{L}(\mathbf{X} - \mathbf{X}')\right) \right\|_2, \quad \mathbf{X}' = \mathbb{E}_{\text{train}}[\mathbf{X}^m], \quad (30)$$

它对输入满足完备性公理，且可下钻到词元维度。遮挡源把窗口 $[k, k + \omega)$ 用相邻段替换（保持序列长度，避免删段变短的伪影），以目标标量的变化量作为该段重要性：

$$w_k^{\text{occ}} = |t(\mathbf{X}) - t(\mathbf{X}_{\setminus [k, k+\omega)})|, \quad \omega = 3. \quad (31)$$

三种来源先在各模态有效区间内做极值归一化，再加权融合：

$$\mathbf{w}^m = \text{norm}\left(\gamma_1 \tilde{\mathbf{w}}^{\text{att}} + \gamma_2 \tilde{\mathbf{w}}^{\text{ig}} + \gamma_3 \tilde{\mathbf{w}}^{\text{occ}}\right), \quad (32)$$

权重 γ 在验证集上以与遮挡源（模型无关基准）的秩相关最大为准则，在约束 $\gamma_i \geq 0.1$ 的单纯形上枚举，得 $\gamma = (0.1, 0.1, 0.8)$ 。之所以给权重设下界，是因为一旦允许取零，最优解会退化为只保留遮挡源，一致性检验也就失去了意义。

6.2.4 证据定位规则

题面要求关键证据可对应至原始文本片段、语音时段或视觉关键帧。附件二不含逐词时间戳，因此需要先确认对齐粒度，在验证集上统计三模态的平均有效长度，文本为 25.59 步、语音 24.59 步、视觉 23.82 步，且文本长度与语音长度的皮尔逊相关系数为 1.000、平均相差 1.00 步（语音少一步对应起始标记），说明对齐版本基本按词级组织。据此为三种模态建立各自的映射规则。

文本证据按词元位置落定，段号即词元位置，用附件给出的文本词元序列（`text_bert`）编号与 BERT 词表（行号即编号）解码 WordPiece 词元、合并续接标记得到词序列，再用序列匹配把词对齐回原始转写文本，得到字符区间；对齐率低于 0.8 的样本单独标记，不做静默降级。

语音证据把高重要度的段号合并为连续区间，按 $t_k \approx \frac{k+0.5}{L_a} T_{\text{video}}$ 映射为秒，并声明该映射为等距近似（附件二不含逐词时间戳），同时用视频音频轨的能量曲线佐证。

视觉证据在最高重要度区间内选择视觉活跃度最大的实际帧，导出该时刻的关键帧图像供回看。

6.3 结果分析与可视化

6.3.1 评价指标与解释质量度量

问题三的预测骨干与问题二相同，因此预测性能继续沿用 5.4.1 节的评价指标与口径，极性采用准确率与宏观 F1、强度采用 MAE 与皮尔逊相关系数（必要时附 CCC），验证集为主报口径、测试划分为泛化核验，预测结果与问题二逐位一致，不重复训练新的预测模型。本问还要回答解释本身好不好这一问题，为此设计了四个指标，另加两项机制检验。

忠实性 (Faithfulness)：删除该模态下重要性排名前 5 的片段后，预测标量的变化量；变化越大，说明被选片段越关键。

充分性偏差 (Sufficiency gap)：仅保留前 5 个重要片段时与全模态预测的差距；差距越小，说明被选片段越充分。

稀疏性 (Sparsity)：前 5 个片段的权重占模态内总权重的比例；过高说明证据过度集中，过低说明解释未聚焦。

稳定性 (Stability)：输入加标准差 0.05 的高斯扰动后重算解释的 L_1 变化；变化越小说明解释越稳定。

机制检验一（与删模态退化的一致性）：模态作用度排序应与真实删模态造成的退化排序一致，且样本级应呈正相关。**机制检验二（免标注检验）**：附件三、附件四带有实测缺失位置，若解释机制成立，则缺失率越高的模态其作用度应越低；该检验不依赖人工标注，可作为解释正确性的外部证据。

6.3.2 典型样本解释卡

解释卡把单个样本的全部解释结果组织为一页可视报告，包括预测结果（极性、强度、置信度）、三模态作用度构成、主要参考模态、各模态时间重要性条带、文本证据词级着色、视觉关键帧与音频能量时段。图 30 展示附件四中预测为正向的样本 17（解释卡含时间重要性条带、文本词级着色、视觉关键帧与音频能量四个面板），模态作用度以文本最大，关键证据落在情绪极性词上，说明模型的判断路径与人类阅读直觉一致。

解释卡 • 样本 17 预测：正向（强度 +1.553， $\theta=0.325$ ，主模态 文本）




图 30 正向样本 17 的解释卡

图 31 与图 32 分别展示预测为负向与中性的解释卡，覆盖三种极性情形。负向样本 16 的文本证据包含明确的否定与贬义线索，模型的关注词与该线索吻合；中性样本 03 的文本证据为事实性描述，其片段重要性分布更为分散、三模态作用度更趋均匀。三类解释卡共同说明，情感越明确，模型越集中地依赖文本证据，而中性样本更容易出现多模态作用度接近的情况。这也给 6.3.4 小节的错误关联分析留下个体层面的直观例证。

解释卡 · 样本 16 预测：负向（强度 -2.492， $\theta=0.325$ ，主模态 文本）



图 31 负向样本 16 的解释卡

解释卡 · 样本 03 预测：中性（强度 -0.299， $\theta=0.325$ ，主模态 文本）



图 32 中性样本 03 的解释卡

6.3.3 三模态作用差异与一致性检验

图 33 汇总了验证集 728 条样本的模态作用度（箱体为四分位区间），文本模态的平均作用度为 0.4620，远高于语音（0.2627）与视觉（0.2754）；按真值极性分层时，负向样本的文本作用度最高（0.5139）、中性样本最低（0.4068）；按强度幅值分层时，文本作用度从 $|y| \in [0, 0.33)$ 的 0.4072 单调升至 $|y| \in [2, 3]$ 的 0.5616，作用度熵由 1.0723 降至 0.9452，即情感越明确、文本依据越集中；语音与视觉的分布在三类情感之间高度重叠，其辅助作用不随极性方向变化。




图 33 验证集三模态作用度按真值极性分层的箱线图

全局子集实验与上述结果一致。以数据集级的负平均绝对误差与宏观 F1 为效用，可得到全局模态重要性；八个模态子集的验证集结果列于表 19。文本单独使用即可把平均绝对误差由 0.7816 降到 0.5936，接近全模态的 0.5866，而语音或视觉单独使用几乎无效；全局 Shapley 值呈现同样的排序，文本 0.1842、语音 0.0004、视觉 0.0103（以负平均绝对误差为效用）。

表 19 八个子集的模态组合在验证集上的表现与全局 Shapley 值

模态子集	强度 MAE	宏观 F1	全局 φ ($-MAE$ 口径)
无（全屏蔽）	0.7816	0.2460	—
文本	0.5936	0.6091	+0.1842
语音	0.7808	0.2560	+0.0004
视觉	0.7676	0.3111	+0.0103
文本 + 语音	0.5933	0.6089	—
文本 + 视觉	0.5867	0.6184	—
语音 + 视觉	0.7670	0.3111	—
全模态	0.5866	0.6158	—

这一排序与问题二的缺失实验完全一致。问题二在缺失率为 1.0 时测得文本、语音、视觉的平均绝对误差增量分别为 +0.1804、+0.0002、+0.0068，即退化由文本主导；本问用完全不同的手段（模态删除后的误差增量，而非缺失注入）测得三者分别为 +0.1804、+0.0001、+0.0067，两者排序完全一致，秩相关系数为 1.000。因此，文本主导这一结论不依赖具体实验手段。图 34 呈现样本级的一致性散点（横轴为删模态后的 MAE 增量、纵轴为作用度，颜色区分模态）： π 的取值以 $\Delta\text{MAE} = 0$ 为轴、随 $|\Delta\text{MAE}|$ 增大而升高，样本级秩相关为 0.156，散点整体呈 V 形包络，即作用度越高的模态对应更大的预测退化，两种度量给出一致的结论。




图 34 样本级一致性检验

进一步地，附件三与附件四的样本带有实测缺失位置，可用于无需标注的机制检验，若解释机制成立，则缺失率越高的模态其作用度应越低。附件三的 30 条样本中， π 与实测缺失率的秩相关系数为 -0.4011，且含缺失模态的平均作用度（0.2898）低于无缺失模态（0.3610）；附件四中仅 1 条样本含缺失（秩相关 +0.0413，样本量不足不作结论）；把两套数据合并（150 组模态-样本观测）后秩相关为 -0.202，整体呈缺失越多、作用度越低的趋势（图 35，圆点为附件三、三角为附件四）。




图 35 免标注机制验证：模态缺失率与作用度的关系

四种解释来源的定量对比如图 36 与表 20 所示（三类指标分别为忠实性、充分性偏差与稀疏性）。注意力源在充分性上明显最差（充分性偏差 0.2596），忠实性与稀疏性也均非最优；积分梯度与遮挡源的忠实性更高；三源融合结果在忠实性（0.0146）与稀疏性（0.4392）之间取得折中，其权重 $\gamma = (0.1, 0.1, 0.8)$ 由验证集按与遮挡源一致性最大的准则标定，对应一致性为 0.9561（等权方案更低）。因此本文以融合结果作为最终解释输出。




图 36 四种解释来源在附件四上的解释质量对比

表 20 解释质量对比（附件四 20 条与验证集 200 条）

解释源	忠实性（附件四）	充分性偏差（附件四）	稀疏性（附件四）	充分性偏差（验证集）	稀疏性（验证集）
注意力（基线）	0.0143	0.2596	0.3580	0.2332	0.4551
积分梯度	0.0171	0.2076	0.3930	0.1972	0.4779
遮挡	0.0163	0.2213	0.4637	0.1938	0.5611
三源融合（本文）	0.0146	0.2251	0.4392	0.1951	0.5310
三源等权（对照）	0.0124	0.2434	0.3778	0.2066	0.4645

6.3.4 片段级证据定位与可读性核查

片段级重要性的分布形态见图 37（三行依次为文本、语音与视觉，样本按预测强度升序排列，颜色越深越关键，红色竖线为有效长度上界）。融合解释的 top-5 片段平均承载 0.439（附件四）的模态内重要度（验证集 200 条为 0.531），最高重要度片段的位置中位数为有效长度的 0.32，即证据集中在各模态有效区间的前中部；附件四 60 个模态-样本中有 59 个的 top-5 片段全部落在有效区间内，未出现把填充位当作证据的情形。积分梯度与遮挡两源在片段级的 top-5 平均仅重叠 1.5/5 个片段，说明时间定位本身存在来源依赖，这也印证了证据在时间上较分散的判断。




图 37 附件四逐段重要性热力图

为进一步检验证据定位的可读性，本文对附件四 20 条样本逐条判读（判读表见支撑材料 Q3_ 证据人工判读 *.csv），文本证据 15/20 承载该样本的情感线索（5 条中性样本为事实性描述，极性样本中 10 条含与预测方向一致的情感、否定或程度线索）；视觉关键帧 19/20 含可辨面部，1 条为房间全景（样本 13）；语音因无听音条件改以能量代理核查，9 条落在高能量或全片峰值段、9 条居中、2 条偏低。图 38 给出关键帧核对的拼图（每格为一条样本的关键帧，上方标注编号与预测强度），将模型导出的关键帧与视频画面逐条对照；未命中集中在寒暄、开场与收尾类语句及远景画面，说明片段级定

位在低信息段会退化为话题匹配，这既支持了模态级结论为主、片段级为辅的取舍，也指出了后续的改进方向。

附件四 关键帧核对表 (19/20 张可用; 标注为 样本号 预测标签 强度 关键帧时刻)




图 38 附件四视觉关键帧核对表 (拼图)

还需指出，上述时间尺度的忠实性指标数值都很小（绝对变化量约 0.0146，而预测强度的标准差为 1.0627），说明本模型的决策证据在时间维度上较为分散、单个片段的替换难以显著改变预测，这与问题二中帧注意力熵 3.86 接近上限 3.91 的实测现象一致。因此本文把模态级解释作为主要的可追溯依据，片段级解释作为辅助定位手段，并在模型改进一节讨论增强时间局部性的方向。解释维度的错误归因如图 39 所示（左、右子图分别为解释熵与置信度），预测正确的 453 条样本其模态作用度的熵均值为 1.0137，预测错误的 275 条为 1.0673，即错误样本的模态依赖更分散、缺少明确的判断依据；两组的平均置信度分别为 0.6771 与 0.5691，说明错误预测通常缺少明显的主导模态；这与问题二中弱强度样本准确率仅 0.5045 的结论一致。

解释维度错误归因（验证集 $n=728$ ，正确 453 / 错误 275）




图 39 解释维度的错误归因

6.3.5 附件四预测与解释结果汇总

附件四 20 条样本的预测与解释汇总见表 21 与图 40（三个面板依次为极性分布、主参考模态与平均强度/置信度）。极性取分类头主口径，模态作用度取式 (29) 的 softmax 口径。预测分布为负向 7 条、中性 5 条、正向 8 条；文本为主要参考模态 18 条、视觉 2 条、语音 0 条，与验证集上文本主导的作用度结论一致。含缺失样本仅 1 条（样本 13 视觉模态整条缺失），其模态作用度趋于均匀、视觉 Shapley 值近似为零，说明模型在信息缺失时不会依赖该模态。




图 40 附件四预测与解释结果汇总

表 21 附件四测试集的预测与解释汇总

指标	全样本	含缺失	无缺失
样本数	20	1	19
平均强度	-0.0540	+0.2921	-0.0722
平均绝对强度	+0.8060	+0.2921	+0.8331
平均置信度	+0.6814	+0.6379	+0.6837
两口径一致率	0.9000	—	—

提交文件 `pred_explain_att4.csv` 逐样本给出五类结果，即情感极性（分类头主口径与阈值口径并列）、情感强度、主要参考模态、三模态作用度（ π_m 与两套归一化）以及关键证据定位（文本字符区间、语音秒区间、视觉关键帧编号与时刻），并附本样本解释的忠实性、充分性、稳定性与稀疏性指标。与预测文件的一致性在生成时做了断言校验，标签逐位一致、强度分数最大差异小于 10^{-3} 。

6.4 本章小结

本章在冻结问题二骨干的基础上搭建了模态级、片段级和证据级三层解释，并完成附件四的全量推理与解释。模态级采用 8 个子集精确枚举 **Shapley** 值（残差小于 10^{-15} ），片段级结合积分梯度和模型无关遮挡，证据级将重要区间映射回文本、语音和视觉；三源融合权重为 $\gamma = (0.1, 0.1, 0.8)$ ，与遮挡基准的一致性达到 0.9561，而注意力源与遮挡源仅为 -0.0268 量级的负相关，说明直接以注意力作解释不成立。

验证集结果显示，文本平均作用度为 0.4620，高于语音 0.2627 和视觉 0.2754，情感越明确文本依据越集中（作用度熵 1.0723 降至 0.9452）。模态级排序与问题二缺失实验的秩相关为 1.000，附件三免标注检验相关系数为 -0.4011。片段级证据大多落在有效区间内（附件四文本证据 15/20 承载情感线索、关键帧 19/20 含可辨面部），但不同解释方法对具体时间位置仍存在一定差异，因此本文将模态级解释作为主要可追溯依据。

本章的限制主要有两点。一是时间片段级的忠实性数值较小（绝对变化量约 0.0146，预测标准差 1.0627），说明证据在时间上较分散；二是附件四只有 1 条含缺失样本，免标注检验的样本量不足。上述局限与改进方向一并列于第 7 章。

七、模型评价与推广

7.1 模型的优点

我们的模型把缺失当作可观测的结构显式纳入，填充掩码、缺失掩码、共享-特有分解和动态门控都有明确的数学含义，能够对应到具体的数据问题。训练和评价口径也

保持一致，模型结构、超参数、阈值和校准系数只在验证集上选择，专项测试集不参与调参；缺失率沿用全文统一定义并与提交文件逐位对齐，分类主口径与阈值口径并列报告。

问题二与问题三从不同途径得到相同的结论，缺失注入实验表明文本模态主导性能退化，删模态反事实与 Shapley 分析得到相同排序（秩相关 1.000）；解释结果又通过附件三实测缺失位置进行免标注检验，并通过注意力不等于重要性的外部基准校验。相比只报告主指标，我们还给出了缺失场景扫描、消融、方差分析、错误归因与拒识分析，使模型的有效范围与不足都可以量化，并同样报告两条经验证无效的改进路径，避免夸大收益。

7.2 模型的缺点

当前模型最明显的问题是中性类边界识别不足，中性类精确率仅约 0.43；连续强度预测也存在向零收缩，负类与正类的平均偏差分别为 +0.541 与 -0.447。部分消融差异小于不同随机种子之间的波动，因此这些模块的独立增益仍需要更多重复实验验证。

另外，真实缺失样本数量有限，验证集中含缺失样本仅 48 条，附件四只有 1 条含缺失样本，且附件三、附件四都没有文本模态实测缺失，这使文本鲁棒性和部分解释结论仍主要依赖模拟实验。片段级解释的忠实性数值较小，说明模型的决策证据在时间上较为分散，片段级定位在低信息段还会退化为话题匹配。

7.3 模型改进与推广

针对中性边界问题，我们尝试过两条低成本路径，结果均未奏效。一条路径是用已有有序回归头的期望替代点回归，在验证集与测试划分上均未改善误差；另一条是用不确定度与强度阈值对中性边界作后处理重判定，八个规则族中仅一个通过判据但只改动一条样本，另一个在验证集上改善 0.0054 而在测试划分上反向恶化 0.0139。这表明瓶颈更多出在表征层面，后续应优先增强否定作用域、转折结构与语用信息的建模；阈值后处理的空间有限，不宜继续复杂化。针对强度收缩，可考虑直接建模带符号的序数分布，使模型同时输出强度层级和不确定度；针对片段级解释分散，可在解释头中加入片段对比约束或稀疏时间窗约束，提高关键证据的局部集中性。

从方法结构看，填充与缺失严格分离、掩码显式感知、训练期缺失注入、独立解释校验的方法框架不依赖情感预测本身，可直接迁移至视频检索、行为识别和工业多传感器时序分析等其他多模态序列任务，只要数据具备等长组织、尾部填充、局部不可用的共性，该框架即可复用；其中缺失口径的定义、课程注入比例与解释一致性标定，是需要按域重新校准的三个关键环节，不宜直接照搬本题参数。

参考文献

- [1] Zadeh A, Liang P P, Poria S, et al. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 2236–2246.
- [2] Tsai Y H H, Bai S, Liang P P, et al. Multimodal transformer for unaligned multimodal language sequences[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019: 6558–6569.
- [3] Cao J, Miranda B, Wang X, et al. A deep multi-task learning model with multiscale feature fusion for multimodal sentiment analysis[J]. Information Fusion, 2023, 91: 232–243.
- [4] Cao W, Mirjalili V, Raschka S. Rank consistent ordinal regression for neural networks with application to age estimation[J]. Pattern Recognition Letters, 2020, 140: 325–331.
- [5] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [6] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning[C]. Proceedings of the 26th Annual International Conference on Machine Learning, 2009: 41–48.
- [7] Geifman Y, El-Yaniv R. Selective classification for deep neural networks[C]. Advances in Neural Information Processing Systems, 2017: 4878–4887.
- [8] Kull M, Silva Filho T, Flach P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers[C]. Artificial Intelligence and Statistics, 2017: 623–631.
- [9] Zhang S, Yang Y, Chen C, et al. Deep learning-based multimodal emotion recognition from audio, visual, and text modalities: A systematic review[J]. Expert Systems with Applications, 2024, 237: 121692.
- [10] Qiu X, Fang Y, Zhou Q, et al. Beyond missing modalities: Hypergraph conditioned diffusion for uncertainty-aware multimodal emotion recognition[C]. CVPR, 2026.
- [11] Yang Z, Li M. Factorize, reconstruct, enhance: A unified framework for multimodal sentiment analysis[C]. CVPR, 2026.
- [12] Zhuang Y, Liu M, Bai W, et al. CMAD: Correlation-aware and modalities-aware distillation for multimodal sentiment analysis with missing modalities[C]. ICCV, 2025.

- [13] Zhu A, Hu M, Wang X, et al. Proxy-driven robust multimodal sentiment analysis with incomplete data[C]. ACL, 2025.
- [14] Mai S, Han S. Learning invariant modality representation for robust multimodal learning from a causal inference perspective[C]. ACL, 2026.
- [15] Wan J, Gong C, Fu G. Locate and explain: Joint multimodal emotion cause extraction and summarization in conversation[C]. ACL, 2026.
- [16] Mai S, Han S. CaReFlow: Cyclic adaptive rectified flow for multimodal fusion[C]. CVPR, 2026.
- [17] Fang Y, Huang W, Wan G, et al. EMOE: Modality-specific enhanced dynamic emotion experts[C]. CVPR, 2025.
- [18] 王楠, 王淇, 欧阳丹彤. 基于知识蒸馏与动态调整机制的多模态情感分析模型 [J]. 计算机学报, 2025, 48(8): 1923–1942.

A 支撑材料文件清单

本次提交的全部支撑材料按类别汇总于表 22（按提交文件、模型参数、结果表、核心代码与运行说明五类列出），文件命名与论文正文、代码中的口径保持一致。问题一的 100 条样本特征文件、处理日志与复现说明待问题一完成后一并提交。

表 22 提交材料清单

类别	文件	说明
提交文件	submission/pred_att3.csv	附件三 30 条预测结果
提交文件	submission/pred_att4.csv	附件四 20 条预测结果
提交文件	submission/pred_explain_att4.csv	附件四预测与解释结果（含模态作用度与证据定位）
提交文件	submission/explain_cards/*.json	逐样本解释卡（含 50 步三源与融合时间重要性）
提交文件	submission/evidence/*.jpg	视觉关键帧（用于回看原始视频）
模型参数	runs/ens_top2/student_s42.pt	集成成员一（种子 42）
模型参数	runs/ens_top2/student_s43.pt	集成成员二（种子 43）
模型参数	runs/q3/q3_evidence_head.pt	可解释性证据头（骨干冻结）
结果表	paper_tables/main_results_summary.csv	主结果多种子汇总
结果表	paper_tables/ablation_paired.csv	同种子配对消融汇总
结果表	paper_tables/missing_low_anova_summary.csv	方差分析效应量
结果表	paper_tables/error_attribution_groups.csv	错误归因分层
结果表	paper_tables/Q3_*.csv	问题三分层作用度、八子集反事实、模态忠实性与解释质量
核心代码	code/02_model/model.py	网络结构与门控
核心代码	code/02_model/losses.py	损失函数与指标
核心代码	code/02_model/train.py	训练与推理主流程
核心代码	code/03_xai/*.py	问题三三源解释与证据定位
运行说明	code/README.md	环境依赖与运行顺序

B 不确定性与拒识能力分析（补充实验）

本节为问题二的可选补充实验，不属于题目硬性要求，正文仅保留结论。

模型在式 (11) 中已输出预测方差，据此可定义两类不确定度。偶然不确定度取对数方差头输出的指数：

$$\sigma_{\text{model}} = \exp(\ln \sigma^2 / 2), \quad (33)$$

认知不确定度由集成成员的分歧给出：

$$\sigma_{\text{ens}} = \sqrt{\frac{1}{K-1} \sum_{k=1}^K (\mu_k - \bar{\mu})^2}, \quad \sigma_{\text{total}} = \sqrt{\sigma_{\text{model}}^2 + \sigma_{\text{ens}}^2}. \quad (34)$$

另一类与极性判别相关的不确定度取分类头概率熵：

$$H = - \sum_{k=0}^2 \pi_k \ln \pi_k. \quad (35)$$

按不确定度升序保留前 q 比例样本，可得风险—覆盖率曲线，其积分即 AURC[7]：

$$\text{AURC} = \int_0^1 \text{MAE}(q) \, dq. \quad (36)$$

两类不确定度对分类准确率的影响方向并不一致，按总不确定度剔除会使准确率下降，按分类头概率熵剔除则明显上升。就强度回归而言，剔除最不确定的 10% 样本后平均绝对误差由 0.5866 降至 0.5465，剔除一半后降至 0.4495；风险—覆盖率曲线的曲线下面积（AURC）为 0.4365（随机剔除对应 0.5866、理论下界 0.2258）；总不确定度与绝对误差的斯皮尔曼相关系数为 0.296（验证集）与 0.230（测试划分），均为正。就极性判别而言，按总不确定度剔除的曲线下面积 0.3980 甚至劣于随机的 0.3777，改用分类头概率熵后降至 0.2252。相关曲线见 5.4.5 节的图 21 至图 23。

用单一不确定度同时拒识回归与分类，在本任务上并不成立，原因在于总不确定度与真值强度单调同增（五分位分桶后最确定一桶的真值绝对强度均值 0.411、最不确定一桶 1.233），实质追踪的是强度幅值；分类头概率熵则与强度递减，追踪的是极性模糊度。据此本文把两类不确定度分别用于强度拒识与极性拒识。

C 核心代码

（本节为骨架占位：正式提交时应以 `lstinputlisting` 自动加载最终代码，保证论文附录、支撑材料与实际运行版本为同一份。）